

Universidad del Valle de Guatemala
Facultad de Ingeniería, Departamento de Ciencias de la Computación
CC3084 – Data Science – Semestre II 2026

Laboratorio 1: Series de Tiempo

Ingreso de viajeros internacionales a Guatemala

Análisis exploratorio, construcción de series mensuales,
pruebas de estacionariedad y modelos de pronóstico
(ARIMA/SARIMA, Prophet, Holt-Winters y Seasonal Naive)
para la serie total, la categoría Vías de ingreso
y la categoría Fronteras.

Parte 1. Análisis Exploratorio

1. Carga y vista general

(161036, 13)

	Año	Mes	cod	Mes	Vía	Frontera	País \
0	2009		1	Ene	Aérea	01 La Aurora	Albania
1	2009		1	Ene	Aérea	01 La Aurora	Alemania
2	2009		1	Ene	Aérea	01 La Aurora	Angola
3	2009		1	Ene	Aérea	01 La Aurora	Arabia Saudita
4	2009		1	Ene	Aérea	01 La Aurora	Argelia

	Región	Región dos	Regiones OMT \
0	OTROS EUROPEOS	Europa	EUROPA MERIDIONAL
1	EUROPA	Europa	EUROPA OCCIDENTAL
2	OTROS PAISES DEL MUNDO	Otros Paises Del Mundo	ÁFRICA CENTRAL
3	OTROS ORIENTE MEDIO	Oriente Medio	ORIENTE MEDIO
4	OTROS PAISES DEL MUNDO	Otros Paises Del Mundo	ÁFRICA DEL NORTE

	MCEO	Agrupación	Residencia	Tipo de Viajero	Viajero
0	08	OTROS	Europa	Turista	1.0
1	04	EUROPA	Europa	Turista	716.0
2	08	OTROS	Resto del Mundo	Turista	4.0
3	08	OTROS	Resto del Mundo	Turista	5.0
4	08	OTROS	Resto del Mundo	Turista	1.0

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 161036 entries, 0 to 161035
Data columns (total 13 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Año                   161036 non-null int64
1   Mes cod               161036 non-null int64
2   Mes                   161036 non-null object
3   Vía                   161036 non-null object
4   Frontera              161036 non-null object
5   País                  161036 non-null object
6   Región                161036 non-null object
7   Región dos            161036 non-null object
8   Regiones OMT          161036 non-null object
9   MCEO                  161036 non-null object
10  Agrupación Residencia 161036 non-null object
11  Tipo de Viajero       161036 non-null object
12  Viajero               161036 non-null float64
dtypes: float64(1), int64(2), object(10)
memory usage: 16.0+ MB
```

13 columnas. Año y Mes cod son numéricas, Viajero es la cantidad de viajeros (float, no siempre entero, ver más abajo), el resto son categóricas: vía, frontera, país, región (tres niveles de agregación distintos: Región, Región dos, Regiones OMT), MCEO, agrupación de residencia y tipo de viajero.

2. Limpieza y calidad de datos

Valores faltantes

```
Año          0
Mes cod      0
Mes          0
Vía          0
Frontera     0
País         0
Región       0
Región dos   0
Regiones OMT 0
MCEO        0
Agrupación Residencia 0
Tipo de Viajero 0
Viajero      0
dtype: int64
```

No hay nulos en ninguna columna.

Duplicados

```
0
```

No hay filas 100% duplicadas. Pero si se agrupa solo por las columnas que identificarían una observación (año, mes, vía, frontera, país, tipo de viajero) aparecen 42 filas repetidas:

```
42 filas
```

```
      Año Mes                               País \
130128 2020 Dic Reino Unido de Gran Bretaña e Irlanda del Norte
130129 2020 Dic Reino Unido de Gran Bretaña e Irlanda del Norte
131981 2021 May                               Federación de Rusia
131982 2021 May                               Federación de Rusia
132717 2021 Jun Reino Unido de Gran Bretaña e Irlanda del Norte
132718 2021 Jun Reino Unido de Gran Bretaña e Irlanda del Norte

      Agrupación Residencia Viajero
130128                Europa      3.0
130129      Resto del Mundo      1.0
131981                Europa     44.0
131982      Resto del Mundo    223.0
132717                Europa      4.0
132718      Resto del Mundo      1.0
```

No son duplicados reales: la misma combinación año/mes/vía/frontera/país/tipo de viajero aparece más de una vez porque el dato se reparte en distintas categorías de Agrupación

Residencia (por ejemplo España se separa en "España" y "Otros Europa" para un mismo mes). Si se eliminaran como duplicados se perdería información real, así que se dejan como están.

Valores atípicos / inconsistentes en columnas categóricas

```
Región dos
Europa                54640
América Del Centro    31362
América Del Sur y el Caribe 24734
América Del Norte     17306
Asia                  13247
Otros Países Del Mundo 8979
Oceanía               5746
Oriente Medio         4805
Cruceiristas          196
0                      13
Cruceiros              8
Name: count, dtype: int64
```

Hay dos categorías raras: '0' (13 filas) y 'Cruceiros' (8 filas), ambas solo en 2022 y asociadas a Tipo de Viajero = Cruceiristas. Son claramente el mismo concepto mal etiquetado, se homologan a 'Cruceiristas':

```
Región dos
Europa                54640
América Del Centro    31362
América Del Sur y el Caribe 24734
América Del Norte     17306
Asia                  13247
Otros Países Del Mundo 8979
Oceanía               5746
Oriente Medio         4805
Cruceiristas          217
Name: count, dtype: int64
```

La columna Viajero


```
valores negativos: 0
valores en cero: 54
valores no enteros: 51272 de 161036
```

	Año	Mes	País	Tipo de Viajero	Viajero
172	2009	Ene	Cruceiristas	Cruceiristas	6518.968580
182	2009	Ene	Cruceiristas	Cruceiristas	6051.031420
260	2009	Ene	Canadá	Excursionista	4.656522
261	2009	Ene	Canadá	Turista	83.817391
262	2009	Ene	Canadá	Viajero	64.526087

No hay negativos. Hay 54 filas en cero (categorías sin viajeros ese mes, es un valor válido, no se eliminan). Cerca de un tercio de las filas tiene valores no enteros, sobre todo en los primeros años y en la categoría Cruceiristas — parece que para ciertos períodos el dato se

prorateó proporcionalmente entre países en lugar de ser un conteo exacto. No afecta el análisis agregado por mes, pero es importante saberlo porque al construir las series no todos los totales van a ser enteros.

Outliers



La variable está fuertemente sesgada a la derecha (media ≈ 325 , mediana = 7, máximo $> 92,000$), lo cual tiene sentido: cada fila es una combinación específica de país/frontera/vía/tipo de viajero, y la mayoría de esas combinaciones son pequeñas (ej. un país lejano cruzando por una frontera terrestre) mientras que unas pocas concentran volúmenes enormes (ej. El Salvador por Valle Nuevo). No se tratan como error, es la naturaleza de los datos desagregados. Al agregar por mes para construir las series de tiempo este problema desaparece.


3. Estadísticas descriptivas

```
count    161036.000000
mean      324.697193
std       2387.745140
min        0.000000
25%        2.000000
50%        7.000000
75%       38.891667
max      92336.035067
Name: Viajero, dtype: float64
```

	count	sum	mean
Tipo de Viajero			
Turista	117912	3.764273e+07	319.244255
Excursionista	19730	9.069184e+06	459.664690
Viajero	23190	4.471622e+06	192.825451
Cruceristas	204	1.104402e+06	5413.735294


Turista es, por mucho, la categoría dominante (~118 mil filas, más de 33 millones de viajeros acumulados). Como indica el enunciado, Viajero (el tipo, no la columna numérica) cae fuerte desde 2023 porque cambió la forma de clasificar a los viajeros no turísticos de alta frecuencia, así que para comparaciones en todo el rango conviene usar Turista + Excursionista.

4. Comportamiento temporal



Se ve una tendencia creciente entre 2009 y 2019, estacionalidad marcada dentro de cada año (picos en diciembre, valles a mitad de año), el desplome casi total durante 2020-2021 por la pandemia, y una recuperación que para 2022 ya supera los niveles pre-pandemia. De 2023 en adelante el nivel se ve más bajo e irregular que 2019, coherente con el cambio de metodología de clasificación mencionado en el enunciado.


5. Países con mayor cantidad de viajeros



País	
El Salvador	1.621398e+07
Guatemala	1.479233e+07
Estados Unidos de América	7.047843e+06
Honduras	2.788233e+06
México	1.808946e+06
Belice	1.328256e+06
Nicaragua	1.164343e+06
Cruceristas	1.078372e+06
Costa Rica	8.821797e+05
Colombia	5.610353e+05
Name: Viajero, dtype: float64	

Los países centroamericanos y Estados Unidos dominan el ranking, lo cual es esperable dado que la mayor parte del ingreso es terrestre y de la región. El top 3 (Guatemala, Estados Unidos, México) va a ser la base para la serie de "países de residencia" si el equipo elige esa categoría.


6. Regiones con mayor cantidad de viajeros



```
Región dos
América Del Centro      3.740653e+07
América Del Norte       9.383035e+06
Europa                  2.222621e+06
América Del Sur y el Caribe 1.447950e+06
Cruceristas             1.105223e+06
Asia                    4.217025e+05
Oceanía                 1.400472e+05
Oriente Medio           1.357125e+05
Otros Países Del Mundo   2.511115e+04
Name: Viajero, dtype: float64
```

América del Centro concentra la mayoría del ingreso, seguida de América del Norte y luego Europa. Las tres primeras (América del Centro, América del Norte, Europa) serían la base de la serie por región geográfica.

7. Vías de ingreso y fronteras más utilizadas



La vía terrestre concentra la mayor parte del ingreso (~32 millones acumulados), muy por encima de la aérea (~19 millones) y la marítima (~1.2 millones). Entre las fronteras, La Aurora (vía aérea) y Valle Nuevo (frontera con El Salvador) son las más usadas por mucho margen.


8. Efecto de la pandemia

caída en abril 2020 vs abril 2019: 97.7%



Abril 2020 tuvo casi 98% menos viajeros que abril 2019. La recuperación empieza a notarse a partir de mediados de 2021 y para 2022 el total mensual ya vuelve a niveles comparables (o mayores) a los de 2019. Esta zona (marzo 2020 - diciembre 2021, sombreada) va a ser importante mencionarla al analizar cada serie individual, porque rompe cualquier patrón de tendencia/estacionalidad que se venía dando antes.

9. Nota sobre el cambio de metodología 2022-2023



Se confirma lo que dice el enunciado: el total "de todas las categorías" muestra una caída fuerte en 2023 que no es real, es un efecto del cambio de clasificación (los viajeros de comercio fronterizo y tránsito dejaron de contarse en "Viajero"). La curva de Turista + Excursionista es mucho más consistente en todo el período y es la que se debería usar para comparar años entre sí.

10. División en entrenamiento y prueba

Como es una serie de tiempo, el split no puede ser aleatorio (rompería el orden temporal y filtraría información del futuro al set de entrenamiento). Se corta cronológicamente: el 70% de los meses más antiguos van a entrenamiento y el 30% más reciente a prueba.

```
mes de corte: 2021-04  
147 de 210 meses en train (70%)
```

```
train: (131442, 13) -> 2009 - hasta 2021-03-01 00:00:00  
test: (29594, 13) -> 2021-04 en adelante  
proporción de filas en train: 81.6%
```


La proporción de filas queda en ~82/18 en vez de 70/30 porque los años recientes tienen menos combinaciones país/frontera reportadas por fila (sobre todo 2020-2021 y post cambio de metodología), pero en términos de meses -que es lo que importa para las series de tiempo- el split sí es 70/30. train.csv es lo que el resto del equipo debe usar para construir y modelar las series; test.csv se deja aparte para evaluar las predicciones al final.

Parte 2. Modelado y Pronóstico

Importing plotly failed. Interactive plots will not work.

1. Construcción de las series

Se agrupa por mes (fecha) la columna Viajero, en total y separado por Vía de ingreso.



Las tres fronteras comparten tendencia creciente entre 2009 y 2019 y un desplome en 2020 y 2021, con volúmenes distintos. La Aurora es el aeropuerto internacional y domina en escala sobre las otras dos, que son pasos terrestres hacia El Salvador: Valle Nuevo sobre la CA-1 y San Cristóbal sobre la CA-8. Al ser fronteras específicas y no vías completas, son más ruidosas mes a mes que las series agregadas de la categoría anterior.


Las cuatro series comparten forma general (tendencia creciente 2009-2019, estacionalidad anual, desplome 2020 por la pandemia), pero con escalas y proporciones distintas: **Terrestre** es la vía dominante, **Aérea** le sigue, y **Marítima** es un orden de magnitud menor y visiblemente más ruidosa. Esto ya anticipa que el modelo que funcione mejor no tiene por qué ser el mismo para las 4 series.

2.1 Serie: Total

a. Inicio, fin y frecuencia


```
Train -> inicio: 2009-01-01 fin: 2021-03-01 n = 147 frecuencia: MS
Test  -> inicio: 2021-04-01 fin: 2026-06-01 n = 63 frecuencia: MS
valores en cero (train): 0
```

b. Gráfico de la serie



Se ve con claridad la misma lectura que en el análisis exploratorio pero ahora aislada: **tendencia creciente 2009-2019** (de ~150 mil a más de 400 mil viajeros/mes), **estacionalidad anual marcada** (picos en diciembre-enero, valle a mitad de año) que se repite todos los años, y un **quiebre abrupto en 2020** donde la serie cae a casi cero y tarda más de un año en recuperarse. La amplitud de los picos estacionales también crece con el nivel de la serie (los picos de 2019 son mucho más altos en términos absolutos que los de 2009), lo que ya sugiere estacionalidad multiplicativa.

c. Descomposición y estacionariedad en media / varianza



Desv. estándar residuo (aditivo): 37845.2

Desv. estándar residuo (multiplicativo, relativo): 0.2038

Desviación estándar por año (evidencia de varianza no constante):

fecha

2009	30046.0
2010	30888.0
2011	31027.0
2012	28152.0
2013	33280.0
2014	41482.0
2015	33599.0
2016	52422.0
2017	54490.0
2018	53089.0
2019	59761.0
2020	158225.0
2021	22760.0

Name: Total, dtype: float64

Tendencia: la componente trend de la descomposición confirma el crecimiento sostenido 2009-2019, la caída de 2020 y la recuperación posterior — no hay nada parecido a una tendencia constante, así que **no hay estacionariedad en media**: el nivel promedio de la serie cambia mucho a lo largo del tiempo.

Estacionalidad: el componente seasonal muestra un patrón anual que se repite con regularidad (correspondiente a la temporada alta/baja de turismo), consistente con lo observado en el gráfico original.

Varianza: la desviación estándar por año calculada arriba **no es constante** — crece de forma bastante sostenida entre 2009 y 2019 (a medida que el nivel de la serie también crece) y se dispara en 2020 por el efecto pandemia. Además, la desviación estándar del residuo de la


descomposición **multiplicativa** se mantiene mucho más estable entre series/niveles que la del modelo **aditivo**, lo que confirma que la amplitud de la estacionalidad y del ruido crece proporcionalmente al nivel de la serie (varianza no constante = heterocedasticidad), típico de series con estacionalidad **multiplicativa**. En conclusión: la serie **no es estacionaria ni en media ni en varianza**.

d. ¿Es necesaria una transformación?

Sí. Como la dispersión de la serie crece con su nivel (varianza no constante / estacionalidad multiplicativa, confirmado en el punto anterior), conviene estabilizar la varianza **antes** de diferenciar o ajustar el ARIMA. Se aplica $\log(x)$ a toda la serie. Esta transformación:


- Convierte la estacionalidad multiplicativa en aditiva (más fácil de modelar con un SARIMA lineal).
- Comprime los valores extremos (los picos de fin de año, y sobre todo el hueco de 2020), reduciendo su influencia desproporcionada sobre la estimación.
- Es invertible: al pronosticar se aplica $\exp()$ para volver a la escala original.

La transformación estabiliza la varianza, pero **no resuelve** por sí sola la falta de estacionariedad en media (tendencia); para eso se necesita diferenciar, lo que se explora en el siguiente punto.



e. No estacionariedad en media: ACF y prueba de Dickey-Fuller Aumentada

i. Gráfico de autocorrelación



En el ACF de la serie en **nivel** (sin diferenciar) los coeficientes decaen muy lentamente y se mantienen altos y significativos durante muchos rezagos (no caen dentro de la banda de confianza rápidamente), con repuntes periódicos cada 12 meses. Ese decaimiento lento —en vez de un corte abrupto— es la firma clásica de una serie **no estacionaria en media**: cada observación está fuertemente correlacionada con muchas observaciones pasadas porque la serie "arrastra" tendencia y estacionalidad en vez de oscilar alrededor de una media fija.

ii. Prueba de Dickey-Fuller Aumentada (ADF)

ADF en nivel	:	estadístico = -2.236	p-valor = 0.1936
ADF 1ra diferencia	:	estadístico = -3.100	p-valor = 0.0265
ADF diferencia est.	:	estadístico = 0.720	p-valor = 0.9902


Con H_0 : "la serie tiene raíz unitaria" (no estacionaria) vs H_1 : "la serie es estacionaria":

- **En nivel**, el p-valor de la prueba ADF es mayor a 0.05, así que **no se rechaza H_0** : hay evidencia estadística formal (no solo visual) de que la serie **no es estacionaria en media**, confirmando la lectura del ACF y de la descomposición.
- **Con una diferencia regular** (diff(1)) el p-valor cae por debajo de 0.05: **se rechaza H_0** , es decir, diferenciar una vez alcanza para estabilizar la media a nivel general.
- **Con solo una diferencia estacional** (diff(12)) el p-valor sigue muy por encima de 0.05: la diferencia estacional sola no es suficiente, todavía queda tendencia sin remover.

Qué hacer para lograr estacionariedad en media: aplicar al menos una diferencia regular ($d = 1$) sobre la serie en logaritmo. Dado que la estacionalidad anual es fuerte (confirmado en la descomposición y en los rezagos 12/24 del ACF), también conviene evaluar una diferencia estacional adicional ($D = 1$, período 12) o, alternativamente, capturar la estacionalidad con términos AR/MA estacionales (P , Q) sin diferenciar estacionalmente — ambas estrategias se comparan en el punto (g).

f. Selección de p , d , q (y P , D , Q) para el ARIMA/SARIMA

Rezagos ACF significativos : [6, 12, 24]
Rezagos PACF significativos: [9]



Sobre la serie ya diferenciada una vez ($d = 1$), se leen ACF/PACF para proponer p y q :

- Los rezagos significativos que sobreviven a la diferenciación **regular** en los rezagos 12 y/o 24 confirman que **todavía queda estructura estacional** sin remover — esto sustenta usar componentes estacionales (P, D o Q en el rezago 12) además de la parte no estacional.
- Los rezagos bajos (1-9, según la serie) significativos en ACF y/o PACF sugieren componentes AR y/o MA de orden bajo (1 a 2) para la parte regular.

Como guía complementaria (y no solo como caja negra) se corre `auto_arima` de `pmdarima`, que busca automáticamente sobre una grilla de $(p,d,q)(P,D,Q)_{12}$ minimizando AIC:

```
Orden sugerido por auto_arima: (3, 0, 2) x (1, 0, 2, 12)
AIC: 67.54 BIC: 97.44
```

`auto_arima` propone **SARIMA(3,0,2)x(1,0,2,12)**: usa $d = 0$ (sin diferencia regular) porque resuelve la tendencia con la parte AR/MA de orden alto en vez de diferenciar, y sí usa estacionalidad explícita en el rezago 12. Tiene sentido en la medida en que es un modelo válido y su AIC/BIC son razonables, pero es un modelo más "cargado" de parámetros (3+2 en la parte regular) que uno construido a mano con $d=1$. Se compara formalmente contra alternativas más simples en el punto (g).

Decisión final de p, d, q (y P, D, Q): con base en el ADF (se necesita al menos $d=1$ o componentes AR/MA que absorban la tendencia), el ACF/PACF diferenciado (estructura de orden bajo, más un rezago fuerte en 12) y contrastando contra `auto_arima`, se arma en el punto (g) una pequeña grilla de modelos candidatos razonables (incluida la propuesta de `auto_arima`) y se elige el mejor por AIC/BIC + diagnóstico de residuos:

Los modelos candidatos evaluados son: SARIMA(1, 1, 1)x(1, 1, 1, 12), SARIMA(2, 1, 2)x(1, 1, 1, 12), SARIMA(3, 0, 2)x(1, 0, 2, 12), SARIMA(0, 1, 1)x(0, 1, 1, 12).

g. Varios modelos ARIMA/SARIMA: AIC, BIC y residuos

```
C:\Users\fabim\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.11_qbz5n2kfra8p0\LocalCache\local-packages\Python311\site-packages\statsmodels\base\model.py:607:
ConvergenceWarning: Maximum Likelihood optimization failed to converge. Check mle_retvals
warnings.warn("Maximum Likelihood optimization failed to "
```

```
C:\Users\fabim\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.11_qbz5n2kfra8p0\LocalCache\local-packages\Python311\site-packages\statsmodels\base\model.py:607:
ConvergenceWarning: Maximum Likelihood optimization failed to converge. Check mle_retvals
warnings.warn("Maximum Likelihood optimization failed to "
```

	modelo	AIC	BIC	ljungbox_p
1	SARIMA(2, 1, 2)x(1, 1, 1, 12)	67.971013	87.424878	0.000230
0	SARIMA(1, 1, 1)x(1, 1, 1, 12)	74.508742	88.446200	0.606380
3	SARIMA(0, 1, 1)x(0, 1, 1, 12)	74.653809	83.016284	0.001476
2	SARIMA(3, 0, 2)x(1, 0, 2, 12)	81.313821	109.188739	0.803252

SARIMAX Results

```

=====
Dep. Variable:                Total    No. Observations:      147
Model:                ARIMA(1, 1, 1)x(1, 1, 1, 12)    Log Likelihood      -32.254
Date:                Sun, 26 Jul 2026    AIC      74.509
Time:                11:13:04    BIC      88.446
Sample:                01-01-2009    HQIC      80.169
                        - 03-01-2021
=====

```

Covariance Type: opg

```

=====
              coef    std err          z      P>|z|      [0.025      0.975]
-----
ar.L1          0.2337      0.920      0.254      0.800      -1.570      2.037
ma.L1         -0.1029      0.951     -0.108      0.914      -1.966      1.760
ar.S.L12      -0.6245      0.387     -1.613      0.107      -1.383      0.134
ma.S.L12      -0.3840      0.443     -0.866      0.386      -1.253      0.485
sigma2         0.0989      0.006     16.537      0.000      0.087      0.111
=====

```

```


=====
Ljung-Box (L1) (Q):                0.00    Jarque-Bera (JB):                9132.97
Prob(Q):                          0.98    Prob(JB):                        0.00
Heteroskedasticity (H):            20.03    Skew:                            -5.06
Prob(H) (two-sided):              0.00    Kurtosis:                       44.52
=====

```

Warnings:

[1] Covariance matrix calculated using the outer product of gradients (complex-step).

Ljung-Box (lag 12) p-valor: 0.6064




Lectura de la tabla: el modelo SARIMA(2,1,2)x(1,1,1,12) tiene el AIC más bajo, pero su prueba de Ljung-Box **rechaza** la hipótesis de residuos ruido blanco (p-valor < 0.05): todavía queda autocorrelación sin explicar, señal de que, pese al buen AIC, el modelo está mal especificado (posible sobreajuste en algunos parámetros que no aportan). Lo mismo le pasa a SARIMA(0,1,1)x(0,1,1,12), que tiene el BIC más bajo pero también reprueba Ljung-Box. SARIMA(3,0,2)x(1,0,2,12) (la propuesta de auto_arma) es el que mejor pasa el diagnóstico de residuos, aunque a costa de un AIC/BIC más altos por su mayor número de parámetros.

El mejor equilibrio entre bondad de ajuste (AIC/BIC razonables, sin ser los más bajos) y residuos que sí se comportan como ruido blanco es **SARIMA(1,1,1)x(1,1,1,12)**: se elige como el mejor modelo ARIMA de este punto (g) por diagnóstico de residuos y parsimonia, aunque como se verá en (h)-(k) eso no garantiza que sea el mejor pronosticando fuera de muestra a 63 meses.

h. Comparación contra Prophet, Holt-Winters y Seasonal Naive

11:13:04 - cmdstanpy - INFO - Chain [1] start processing

11:13:04 - cmdstanpy - INFO - Chain [1] done processing



El gráfico ya deja ver el problema de fondo: los cuatro modelos se entrenaron únicamente con información hasta marzo de 2021 (fondo de la pandemia) y se les pide pronosticar 63 meses - casi 5 años- hacia adelante, un horizonte muy largo para un modelo mensual sin variables exógenas. Ninguno de los cuatro puede anticipar la magnitud real de la recuperación pospandemia ni el cambio de metodología de clasificación de 2022-2023 detectado en el análisis exploratorio, porque esa información simplemente no estaba en los datos de entrenamiento.

i. Predicción del mejor modelo sobre el conjunto de prueba

(Se calcula formalmente en el punto (j))/(k) cuál es el mejor modelo; aquí se deja ya el código genérico de pronóstico -- reutiliza pred_arima, pred_hw, pred_pr y pred_naive calculados en el punto anterior, que son las predicciones de cada modelo sobre el mismo conjunto de prueba.)

	real	ARIMA	Holt-Winters	Prophet	SeasonalNaive
fecha					
2021-04-01	82068.0	114268.0	101957.0	260492.0	10039.0
2021-05-01	79974.0	86551.0	82859.0	213729.0	9779.0
2021-06-01	106436.0	96325.0	92059.0	228949.0	11817.0
2021-07-01	108346.0	110084.0	105304.0	253473.0	13484.0
2021-08-01	83251.0	114181.0	109666.0	257345.0	15357.0
2021-09-01	74914.0	83676.0	82538.0	194020.0	25390.0
2021-10-01	93745.0	88645.0	95086.0	218090.0	30539.0
2021-11-01	116908.0	103668.0	111721.0	251851.0	58632.0
2021-12-01	246898.0	133035.0	144731.0	317166.0	59432.0
2022-01-01	151709.0	118558.0	124980.0	270092.0	104620.0
2022-02-01	232198.0	97608.0	103501.0	218636.0	65463.0
2022-03-01	296130.0	66063.0	117307.0	253298.0	105145.0

j. Comparación de modelos: MAE, RMSE, AIC, BIC

	AIC	BIC	MAE	RMSE
modelo				
ARIMA(1, 1, 1)x(1, 1, 1, 12)	74.51	88.45	246695.96	271281.69
Holt-Winters	NaN	NaN	148782.44	168288.81
Prophet	NaN	NaN	97588.78	107975.46
SeasonalNaive	NaN	NaN	235730.91	253203.39

k. Selección del mejor modelo

Serie	Mejor ARIMA (AIC/BIC/residuos)	MAE ARIMA	Mejor modelo global	MAE mejor global
Total	SARIMA(1,1,1)x(1,1,1,12)	≈ 247 mil	Prophet	≈ 98 mil

Para la serie **Total**, el mejor ARIMA elegido en (g) por AIC/BIC + residuos (SARIMA(1,1,1)x(1,1,1,12)) queda claramente por detrás de **Prophet** en las métricas fuera de muestra (MAE y RMSE de Prophet son menos de la mitad que las del mejor ARIMA), y también por detrás de Holt-Winters. Esto tiene una explicación razonable: Prophet modela la tendencia con "changepoints" que le permiten adaptar la pendiente después del quiebre de 2020 de forma más flexible que un SARIMA con parámetros fijos estimados solo con datos hasta marzo de 2021 (que en la práctica termina extrapolando linealmente en escala log la tendencia pre-quiebre, sin adaptarse al tamaño real de la recuperación). Seasonal Naive, sin embargo, queda por debajo del mejor ARIMA en error, lo cual es una señal de alerta: para esta serie y este horizonte tan largo, ni siquiera el mejor SARIMA logra superar a "repetir el último ciclo anual observado".

Selección final para Total: Prophet, por tener el menor MAE y RMSE fuera de muestra entre todos los modelos comparados.

2.2 Serie: Aérea

a. Inicio, fin y frecuencia


```
Train -> inicio: 2009-01-01 fin: 2021-03-01 n = 147 frecuencia: MS
Test  -> inicio: 2021-04-01 fin: 2026-06-01 n = 63 frecuencia: MS
valores en cero (train): 0
```

b. Gráfico de la serie



La vía aérea también muestra tendencia creciente y estacionalidad anual, pero con un patrón estacional distinto al de la serie Total: los picos coinciden con diciembre y con la temporada alta de turismo internacional (marzo-abril), y el valle de mitad de año es menos profundo en términos relativos. El desplome de 2020 es, proporcionalmente, el más severo de las tres vías (el tráfico aéreo internacional se detuvo casi por completo), y la recuperación es visiblemente más lenta que la de la serie Total.

c. Descomposición y estacionariedad en media / varianza



Desv. estándar residuo (aditivo): 10956.2

Desv. estándar residuo (multiplicativo, relativo): 0.2178

Desviación estándar por año (evidencia de varianza no constante):

fecha

2009	10935.0
2010	12323.0
2011	11154.0
2012	11175.0
2013	13402.0
2014	11961.0
2015	14124.0
2016	13616.0
2017	16656.0
2018	18001.0
2019	15694.0
2020	46009.0
2021	15695.0

Name: Aérea, dtype: float64

Tendencia: la componente trend de la descomposición confirma el crecimiento sostenido 2009-2019, la caída de 2020 y la recuperación posterior — no hay nada parecido a una tendencia constante, así que **no hay estacionariedad en media**: el nivel promedio de la serie cambia mucho a lo largo del tiempo.

Estacionalidad: el componente seasonal muestra un patrón anual que se repite con regularidad (correspondiente a la temporada alta/baja de turismo), consistente con lo observado en el gráfico original.

Varianza: la desviación estándar por año calculada arriba **no es constante** — crece de forma bastante sostenida entre 2009 y 2019 (a medida que el nivel de la serie también crece) y se dispara en 2020 por el efecto pandemia. Además, la desviación estándar del residuo de la


descomposición **multiplicativa** se mantiene mucho más estable entre series/niveles que la del modelo **aditivo**, lo que confirma que la amplitud de la estacionalidad y del ruido crece proporcionalmente al nivel de la serie (varianza no constante = heterocedasticidad), típico de series con estacionalidad **multiplicativa**. En conclusión: la serie **no es estacionaria ni en media ni en varianza**.

d. ¿Es necesaria una transformación?

Sí. Como la dispersión de la serie crece con su nivel (varianza no constante / estacionalidad multiplicativa, confirmado en el punto anterior), conviene estabilizar la varianza **antes** de diferenciar o ajustar el ARIMA. Se aplica $\log(x)$ a toda la serie. Esta transformación:


- Convierte la estacionalidad multiplicativa en aditiva (más fácil de modelar con un SARIMA lineal).
- Comprime los valores extremos (los picos de fin de año, y sobre todo el hueco de 2020), reduciendo su influencia desproporcionada sobre la estimación.
- Es invertible: al pronosticar se aplica $\exp()$ para volver a la escala original.

La transformación estabiliza la varianza, pero **no resuelve** por sí sola la falta de estacionariedad en media (tendencia); para eso se necesita diferenciar, lo que se explora en el siguiente punto.



e. No estacionariedad en media: ACF y prueba de Dickey-Fuller Aumentada

i. Gráfico de autocorrelación



En el ACF de la serie en **nivel** (sin diferenciar) los coeficientes decaen muy lentamente y se mantienen altos y significativos durante muchos rezagos (no caen dentro de la banda de confianza rápidamente), con repuntes periódicos cada 12 meses. Ese decaimiento lento —en vez de un corte abrupto— es la firma clásica de una serie **no estacionaria en media**: cada observación está fuertemente correlacionada con muchas observaciones pasadas porque la serie "arrastra" tendencia y estacionalidad en vez de oscilar alrededor de una media fija.

ii. Prueba de Dickey-Fuller Aumentada (ADF)

ADF en nivel	:	estadístico = -4.018	p-valor = 0.0013
ADF 1ra diferencia	:	estadístico = -3.214	p-valor = 0.0192
ADF diferencia est.	:	estadístico = -0.727	p-valor = 0.8396


Con H_0 : "la serie tiene raíz unitaria" (no estacionaria) vs H_1 : "la serie es estacionaria":

- **En nivel**, el p-valor de la prueba ADF es mayor a 0.05, así que **no se rechaza H_0** : hay evidencia estadística formal (no solo visual) de que la serie **no es estacionaria en media**, confirmando la lectura del ACF y de la descomposición.
- **Con una diferencia regular** (diff(1)) el p-valor cae por debajo de 0.05: **se rechaza H_0** , es decir, diferenciar una vez alcanza para estabilizar la media a nivel general.
- **Con solo una diferencia estacional** (diff(12)) el p-valor sigue muy por encima de 0.05: la diferencia estacional sola no es suficiente, todavía queda tendencia sin remover.

Qué hacer para lograr estacionariedad en media: aplicar al menos una diferencia regular ($d = 1$) sobre la serie en logaritmo. Dado que la estacionalidad anual es fuerte (confirmado en la descomposición y en los rezagos 12/24 del ACF), también conviene evaluar una diferencia estacional adicional ($D = 1$, período 12) o, alternativamente, capturar la estacionalidad con términos AR/MA estacionales (P , Q) sin diferenciar estacionalmente — ambas estrategias se comparan en el punto (g).

f. Selección de p , d , q (y P , D , Q) para el ARIMA/SARIMA

Rezagos ACF significativos	:	[5, 7]
Rezagos PACF significativos	:	[5, 7]



Sobre la serie ya diferenciada una vez ($d = 1$), se leen ACF/PACF para proponer p y q :

- Los rezagos significativos que sobreviven a la diferenciación **regular** en los rezagos 12 y/o 24 confirman que **todavía queda estructura estacional** sin remover — esto sustenta usar componentes estacionales (P, D o Q en el rezago 12) además de la parte no estacional.
- Los rezagos bajos (1-9, según la serie) significativos en ACF y/o PACF sugieren componentes AR y/o MA de orden bajo (1 a 2) para la parte regular.

Como guía complementaria (y no solo como caja negra) se corre auto_arima de pmdarima, que busca automáticamente sobre una grilla de (p,d,q)(P,D,Q)\${}_{12}\$ minimizando AIC:

Orden sugerido por auto_arima: (1, 0, 1) x (1, 0, 1, 12)
AIC: 185.62 BIC: 203.56

auto_arima propone **SARIMA(1,0,1)x(1,0,1,12)**, también con d=0: usa un AR(1)/MA(1) para capturar la persistencia y componentes estacionales de orden 1 para el ciclo anual, sin diferenciar. Es un modelo razonablemente parsimonioso (pocos parámetros) y, como se ve en (g), resulta ser de hecho el más **estable** al pronosticar, así que la propuesta de auto_arima sí tiene sentido aquí.

Decisión final de p, d, q (y P, D, Q): con base en el ADF (se necesita al menos d=1 o componentes AR/MA que absorban la tendencia), el ACF/PACF diferenciado (estructura de orden bajo, más un rezago fuerte en 12) y contrastando contra auto_arima, se arma en el punto (g) una pequeña grilla de modelos candidatos razonables (incluida la propuesta de auto_arima) y se elige el mejor por AIC/BIC + diagnóstico de residuos:

Los modelos candidatos evaluados son: SARIMA(1, 1, 1)x(1, 1, 1, 12), SARIMA(1, 0, 1)x(1, 0, 1, 12), SARIMA(2, 1, 1)x(0, 1, 1, 12), SARIMA(1, 1, 0)x(1, 1, 0, 12).

g. Varios modelos ARIMA/SARIMA: AIC, BIC y residuos

	modelo	AIC	BIC	ljungbox_p
3	SARIMA(1, 1, 0)x(1, 1, 0, 12)	167.428432	175.815803	1.000000
0	SARIMA(1, 1, 1)x(1, 1, 1, 12)	169.121190	183.058649	0.999996
2	SARIMA(2, 1, 1)x(0, 1, 1, 12)	179.469092	193.406551	0.004967
1	SARIMA(1, 0, 1)x(1, 0, 1, 12)	180.386649	197.728743	0.203234

SARIMAX Results

```

=====
Dep. Variable:          Aérea      No. Observations:      147
Model:                ARIMA(1, 0, 1)x(1, 0, 1, 12)  Log Likelihood      -84.193
Date:                  Sun, 26 Jul 2026      AIC      180.387
Time:                  11:13:17      BIC      197.729
Sample:                01-01-2009      HQIC      187.434
                    - 03-01-2021
=====

```

Covariance Type: opg

```

=====
              coef      std err          z      P>|z|      [0.025      0.975]
-----
const          10.6389      4.723      2.253      0.024      1.383     19.895
ar.L1           0.8343      0.068     12.214      0.000      0.700      0.968
ma.L1           0.2466      0.101      2.441      0.015      0.049      0.445
ar.S.L12        0.8407      0.478      1.758      0.079     -0.097      1.778
ma.S.L12       -0.4432      0.481     -0.922      0.356     -1.385      0.499
sigma2          0.2035      0.018     11.340      0.000      0.168      0.239
=====

```

```


=====
Ljung-Box (L1) (Q):          0.00      Jarque-Bera (JB):          35220.22
Prob(Q):                    0.95      Prob(JB):              0.00
Heteroskedasticity (H):      76.17      Skew:              -7.81
Prob(H) (two-sided):        0.00      Kurtosis:           81.18
=====

```

Warnings:

[1] Covariance matrix calculated using the outer product of gradients (complex-step).

Ljung-Box (lag 12) p-valor: 0.2032




Lectura de la tabla — con una advertencia importante: los modelos SARIMA(1,1,1)x(1,1,1,12) y SARIMA(1,1,0)x(1,1,0,12) muestran el AIC/BIC más bajos y superan la prueba de Ljung-Box, así que a simple vista parecerían los mejores. Pero al usarlos para pronosticar los 63 meses de prueba, el error se dispara a valores absurdos (billones). Esto ocurre porque, al combinar diferencia regular + diferencia estacional + componentes AR y MA en la escala logarítmica, los polinomios característicos quedan con raíces muy cercanas al círculo unitario: el ajuste dentro de la muestra de entrenamiento se ve bien, pero la ecuación de pronóstico se vuelve explosiva al proyectarla 5 años hacia adelante. Es un buen ejemplo de por qué **AIC/BIC y Ljung-Box no son suficientes**: hay que verificar también que el modelo sea estable/invertible y que sus pronósticos fuera de muestra sean razonables antes de declararlo "el mejor".

Descartando esos dos modelos inestables, el mejor modelo ARIMA viable es **SARIMA(1,0,1)x(1,0,1,12)** (la propuesta de auto_arima): buen AIC/BIC relativo, Ljung-Box que no rechaza ruido blanco, y pronósticos estables y razonables.

h. Comparación contra Prophet, Holt-Winters y Seasonal Naive

```
11:13:18 - cmdstanpy - INFO - Chain [1] start processing
```

```
11:13:18 - cmdstanpy - INFO - Chain [1] done processing
```



El gráfico ya deja ver el problema de fondo: los cuatro modelos se entrenaron únicamente con información hasta marzo de 2021 (fondo de la pandemia) y se les pide pronosticar 63 meses - casi 5 años- hacia adelante, un horizonte muy largo para un modelo mensual sin variables exógenas. Ninguno de los cuatro puede anticipar la magnitud real de la recuperación pospandemia ni el cambio de metodología de clasificación de 2022-2023 detectado en el análisis exploratorio, porque esa información simplemente no estaba en los datos de entrenamiento.

i. Predicción del mejor modelo sobre el conjunto de prueba

(Se calcula formalmente en el punto (j))/(k) cuál es el mejor modelo; aquí se deja ya el código genérico de pronóstico -- reutiliza `pred_arima`, `pred_hw`, `pred_pr` y `pred_naive` calculados en el punto anterior, que son las predicciones de cada modelo sobre el mismo conjunto de prueba.)

	real	ARIMA	Holt-Winters	Prophet	SeasonalNaive
fecha					
2021-04-01	34542.0	11547.0	54213.0	66765.0	489.0
2021-05-01	59518.0	11892.0	50233.0	59135.0	610.0
2021-06-01	75987.0	17129.0	61763.0	75167.0	1418.0
2021-07-01	71180.0	15378.0	68659.0	83683.0	1047.0
2021-08-01	55680.0	15273.0	56301.0	64194.0	1259.0
2021-09-01	46048.0	26153.0	49262.0	52094.0	5606.0
2021-10-01	53420.0	33688.0	59361.0	64740.0	9475.0
2021-11-01	72673.0	61226.0	68541.0	78242.0	38994.0
2021-12-01	122254.0	72118.0	80572.0	94801.0	53717.0
2022-01-01	97752.0	62089.0	66869.0	73515.0	43648.0
2022-02-01	84575.0	49842.0	57727.0	58601.0	28784.0
2022-03-01	106141.0	59873.0	64944.0	70163.0	60160.0

j. Comparación de modelos: MAE, RMSE, AIC, BIC

	AIC	BIC	MAE	RMSE
modelo				
ARIMA(1, 0, 1)x(1, 0, 1, 12)	180.39	197.73	59086.49	63483.93
Holt-Winters	NaN	NaN	24619.26	29846.35
Prophet	NaN	NaN	44233.00	49111.14
SeasonalNaive	NaN	NaN	75103.70	79077.33

k. Selección del mejor modelo

Serie	Mejor ARIMA (AIC/BIC/residuos)	MAE ARIMA	Mejor modelo global	MAE mejor global
Aérea	SARIMA(1,0,1)x(1,0,1,12)	≈ 59 mil	Holt-Winters	≈ 25 mil

Para **Aérea**, el mejor ARIMA viable (recordando que se descartaron dos candidatos con AIC/BIC mejores pero pronósticos numéricamente explosivos) tiene un MAE considerablemente peor que Holt-Winters, que resulta ser aquí el modelo más preciso de los cuatro, incluso por encima de Prophet. Una posible explicación: la vía aérea tiene una estacionalidad muy regular y una tendencia relativamente suave fuera del choque de 2020, así que un suavizamiento exponencial triple con tendencia aditiva amortiguable "ajustada" directamente sobre la escala original capta bien ese patrón sin necesitar tantos parámetros como un SARIMA ni el mecanismo de changepoints de Prophet (que, para esta serie, parece sobre-ajustar la forma de la recuperación observada en el propio 2021 dentro del set de entrenamiento).


Selección final para Aérea: Holt-Winters, por tener el menor MAE y RMSE fuera de muestra.

2.3 Serie: Terrestre

a. Inicio, fin y frecuencia


```
Train -> inicio: 2009-01-01 fin: 2021-03-01 n = 147 frecuencia: MS  
Test  -> inicio: 2021-04-01 fin: 2026-06-01 n = 63 frecuencia: MS  
valores en cero (train): 0
```

b. Gráfico de la serie



Terrestre es la vía de mayor volumen y domina visualmente la forma de la serie Total (son muy parecidas). Tiene tendencia creciente, estacionalidad anual y el mismo quiebre de 2020, aunque la caída es algo menos abrupta que en la vía aérea (los cruces terrestres nunca llegaron completamente a cero, a diferencia de los vuelos internacionales) y la recuperación es más rápida.

c. Descomposición y estacionariedad en media / varianza



Desv. estándar residuo (aditivo): 28281.9

Desv. estándar residuo (multiplicativo, relativo): 0.2074

Desviación estándar por año (evidencia de varianza no constante):

fecha

2009	16934.0
2010	17417.0
2011	19611.0
2012	16253.0
2013	18977.0
2014	29963.0
2015	21165.0
2016	39672.0
2017	45711.0
2018	40675.0
2019	47819.0
2020	107681.0
2021	12347.0

Name: Terrestre, dtype: float64

Tendencia: la componente trend de la descomposición confirma el crecimiento sostenido 2009-2019, la caída de 2020 y la recuperación posterior — no hay nada parecido a una tendencia constante, así que **no hay estacionariedad en media**: el nivel promedio de la serie cambia mucho a lo largo del tiempo.

Estacionalidad: el componente seasonal muestra un patrón anual que se repite con regularidad (correspondiente a la temporada alta/baja de turismo), consistente con lo observado en el gráfico original.

Varianza: la desviación estándar por año calculada arriba **no es constante** — crece de forma bastante sostenida entre 2009 y 2019 (a medida que el nivel de la serie también crece) y se dispara en 2020 por el efecto pandemia. Además, la desviación estándar del residuo de la


descomposición **multiplicativa** se mantiene mucho más estable entre series/niveles que la del modelo **aditivo**, lo que confirma que la amplitud de la estacionalidad y del ruido crece proporcionalmente al nivel de la serie (varianza no constante = heterocedasticidad), típico de series con estacionalidad **multiplicativa**. En conclusión: la serie **no es estacionaria ni en media ni en varianza**.

d. ¿Es necesaria una transformación?

Sí. Como la dispersión de la serie crece con su nivel (varianza no constante / estacionalidad multiplicativa, confirmado en el punto anterior), conviene estabilizar la varianza **antes** de diferenciar o ajustar el ARIMA. Se aplica $\log(x)$ a toda la serie. Esta transformación:


- Convierte la estacionalidad multiplicativa en aditiva (más fácil de modelar con un SARIMA lineal).
- Comprime los valores extremos (los picos de fin de año, y sobre todo el hueco de 2020), reduciendo su influencia desproporcionada sobre la estimación.
- Es invertible: al pronosticar se aplica $\exp()$ para volver a la escala original.

La transformación estabiliza la varianza, pero **no resuelve** por sí sola la falta de estacionariedad en media (tendencia); para eso se necesita diferenciar, lo que se explora en el siguiente punto.



e. No estacionariedad en media: ACF y prueba de Dickey-Fuller Aumentada

i. Gráfico de autocorrelación



En el ACF de la serie en **nivel** (sin diferenciar) los coeficientes decaen muy lentamente y se mantienen altos y significativos durante muchos rezagos (no caen dentro de la banda de confianza rápidamente), con repuntes periódicos cada 12 meses. Ese decaimiento lento —en vez de un corte abrupto— es la firma clásica de una serie **no estacionaria en media**: cada observación está fuertemente correlacionada con muchas observaciones pasadas porque la serie "arrastra" tendencia y estacionalidad en vez de oscilar alrededor de una media fija.

ii. Prueba de Dickey-Fuller Aumentada (ADF)

ADF en nivel	:	estadístico = -1.442	p-valor = 0.5619
ADF 1ra diferencia	:	estadístico = -3.460	p-valor = 0.0091
ADF diferencia est.	:	estadístico = 0.220	p-valor = 0.9734


Con H_0 : "la serie tiene raíz unitaria" (no estacionaria) vs H_1 : "la serie es estacionaria":

- **En nivel**, el p-valor de la prueba ADF es mayor a 0.05, así que **no se rechaza H_0** : hay evidencia estadística formal (no solo visual) de que la serie **no es estacionaria en media**, confirmando la lectura del ACF y de la descomposición.
- **Con una diferencia regular** (diff(1)) el p-valor cae por debajo de 0.05: **se rechaza H_0** , es decir, diferenciar una vez alcanza para estabilizar la media a nivel general.
- **Con solo una diferencia estacional** (diff(12)) el p-valor sigue muy por encima de 0.05: la diferencia estacional sola no es suficiente, todavía queda tendencia sin remover.

Qué hacer para lograr estacionariedad en media: aplicar al menos una diferencia regular ($d = 1$) sobre la serie en logaritmo. Dado que la estacionalidad anual es fuerte (confirmado en la descomposición y en los rezagos 12/24 del ACF), también conviene evaluar una diferencia estacional adicional ($D = 1$, período 12) o, alternativamente, capturar la estacionalidad con términos AR/MA estacionales (P, Q) sin diferenciar estacionalmente — ambas estrategias se comparan en el punto (g).

f. Selección de p, d, q (y P, D, Q) para el ARIMA/SARIMA

Rezagos ACF significativos	:	[1, 8, 9, 24]
Rezagos PACF significativos	:	[1, 8, 9, 10, 17]



Sobre la serie ya diferenciada una vez ($d = 1$), se leen ACF/PACF para proponer p y q :

- Los rezagos significativos que sobreviven a la diferenciación **regular** en los rezagos 12 y/o 24 confirman que **todavía queda estructura estacional** sin remover — esto sustenta usar componentes estacionales (P, D o Q en el rezago 12) además de la parte no estacional.
- Los rezagos bajos (1-9, según la serie) significativos en ACF y/o PACF sugieren componentes AR y/o MA de orden bajo (1 a 2) para la parte regular.

Como guía complementaria (y no solo como caja negra) se corre `auto_arima` de `pmdarima`, que busca automáticamente sobre una grilla de $(p,d,q)(P,D,Q)_{12}$ minimizando AIC:

Orden sugerido por `auto_arima`: (1, 0, 0) x (2, 0, 0, 12)
AIC: 128.64 BIC: 143.59

`auto_arima` propone **SARIMA(1,0,0)x(0,0,2,12)**: de nuevo $d=0$, con un solo AR regular y dos componentes MA estacionales. Tiene el mejor AIC/BIC de la grilla probada en (g), pero (como se confirma abajo) sus residuos no pasan la prueba de Ljung-Box, así que aunque el ajuste numérico es bueno, no captura toda la estructura de autocorrelación -- no es, por sí solo, un modelo completamente bien especificado.

Decisión final de p, d, q (y P, D, Q): con base en el ADF (se necesita al menos $d=1$ o componentes AR/MA que absorban la tendencia), el ACF/PACF diferenciado (estructura de orden bajo, más un rezago fuerte en 12) y contrastando contra `auto_arima`, se arma en el punto (g) una pequeña grilla de modelos candidatos razonables (incluida la propuesta de `auto_arima`) y se elige el mejor por AIC/BIC + diagnóstico de residuos:

Los modelos candidatos evaluados son: SARIMA(1, 1, 1)x(1, 1, 1, 12), SARIMA(1, 0, 0)x(0, 0, 2, 12), SARIMA(2, 1, 1)x(1, 1, 0, 12), SARIMA(0, 1, 1)x(0, 1, 1, 12).

g. Varios modelos ARIMA/SARIMA: AIC, BIC y residuos

	modelo	AIC	BIC	ljungbox_p
1	SARIMA(1, 0, 0)x(0, 0, 2, 12)	124.708907	138.729012	0.009320
3	SARIMA(0, 1, 1)x(0, 1, 1, 12)	125.557330	133.919806	0.002729
0	SARIMA(1, 1, 1)x(1, 1, 1, 12)	127.330660	141.268119	0.125636
2	SARIMA(2, 1, 1)x(1, 1, 0, 12)	128.316195	142.253654	0.820807

SARIMAX Results

```
=====
Dep. Variable:          Terrestre      No. Observations:      147
Model:                ARIMA(1, 1, 1)x(1, 1, 1, 12)  Log Likelihood        -58.665
Date:                 Sun, 26 Jul 2026  AIC              127.331
Time:                 11:13:24          BIC              141.268
Sample:               01-01-2009       HQIC             132.991
                        - 03-01-2021
=====
```

Covariance Type: opg


```
=====
              coef    std err          z      P>|z|      [0.025      0.975]
-----
ar.L1          0.4926     0.376      1.312     0.190     -0.244      1.229
ma.L1         -0.6520     0.375     -1.740     0.082     -1.387      0.083
ar.S.L12      -0.5584     0.459     -1.216     0.224     -1.459      0.342
ma.S.L12      -0.2346     0.556     -0.422     0.673     -1.325      0.856
sigma2         0.1549     0.006     24.192     0.000      0.142      0.167
=====
```

```
=====
Ljung-Box (L1) (Q):      0.06  Jarque-Bera (JB):      3304.28
Prob(Q):                0.81  Prob(JB):              0.00
Heteroskedasticity (H):  22.48  Skew:              -1.70
Prob(H) (two-sided):    0.00  Kurtosis:           28.48
=====
```

Warnings:

[1] Covariance matrix calculated using the outer product of gradients (complex-step).

Ljung-Box (lag 12) p-valor: 0.1256




Lectura de la tabla: SARIMA(1,0,0)x(0,0,2,12) (la sugerencia de auto_arima) tiene el mejor AIC y BIC, pero reprueba Ljung-Box (residuos con autocorrelación remanente). Lo mismo le pasa a SARIMA(0,1,1)x(0,1,1,12), que tiene el segundo mejor BIC. En cambio, SARIMA(2,1,1)x(1,1,0,12) y SARIMA(1,1,1)x(1,1,1,12) sí superan Ljung-Box (residuos consistentes con ruido blanco), con AIC/BIC apenas un poco más altos.

Se elige **SARIMA(1,1,1)x(1,1,1,12)** como mejor modelo ARIMA de este punto: es el que mejor combina un AIC/BIC competitivo con residuos que sí pasan el diagnóstico de blancura, y además (a diferencia de lo que pasó en Aérea) su pronóstico a 63 meses no se vuelve inestable.

h. Comparación contra Prophet, Holt-Winters y Seasonal Naive

11:13:24 - cmdstanpy - INFO - Chain [1] start processing

11:13:24 - cmdstanpy - INFO - Chain [1] done processing



El gráfico ya deja ver el problema de fondo: los cuatro modelos se entrenaron únicamente con información hasta marzo de 2021 (fondo de la pandemia) y se les pide pronosticar 63 meses - casi 5 años- hacia adelante, un horizonte muy largo para un modelo mensual sin variables exógenas. Ninguno de los cuatro puede anticipar la magnitud real de la recuperación pospandemia ni el cambio de metodología de clasificación de 2022-2023 detectado en el análisis exploratorio, porque esa información simplemente no estaba en los datos de entrenamiento.

i. Predicción del mejor modelo sobre el conjunto de prueba

(Se calcula formalmente en el punto (j))/(k) cuál es el mejor modelo; aquí se deja ya el código genérico de pronóstico -- reutiliza `pred_arima`, `pred_hw`, `pred_pr` y `pred_naive` calculados en el punto anterior, que son las predicciones de cada modelo sobre el mismo conjunto de prueba.)

	real	ARIMA	Holt-Winters	Prophet	SeasonalNaive
fecha					
2021-04-01	47526.0	26270.0	45010.0	185188.0	9550.0
2021-05-01	20456.0	19157.0	35513.0	152525.0	9169.0
2021-06-01	30449.0	20847.0	38657.0	156984.0	10399.0
2021-07-01	37166.0	24358.0	45214.0	173471.0	12437.0
2021-08-01	27571.0	27713.0	53215.0	192307.0	14098.0
2021-09-01	28866.0	22142.0	37391.0	144988.0	19784.0
2021-10-01	40325.0	20727.0	40277.0	152406.0	21064.0
2021-11-01	42922.0	23520.0	46360.0	166230.0	19638.0
2021-12-01	122049.0	24054.0	65127.0	213900.0	5715.0
2022-01-01	53281.0	36467.0	56928.0	188582.0	60972.0
2022-02-01	147175.0	27901.0	46716.0	154515.0	36679.0
2022-03-01	189137.0	18816.0	53498.0	177378.0	44985.0

j. Comparación de modelos: MAE, RMSE, AIC, BIC

	AIC	BIC	MAE	RMSE
modelo				
ARIMA(1, 1, 1)x(1, 1, 1, 12)	127.33	141.27	174582.18	191965.97
Holt-Winters	NaN	NaN	119819.88	135351.23
Prophet	NaN	NaN	54280.09	71294.24
SeasonalNaive	NaN	NaN	160013.01	176652.99

k. Selección del mejor modelo

Serie	Mejor ARIMA (AIC/BIC/residuos)	MAE ARIMA	Mejor modelo global	MAE mejor global
Terrestre	SARIMA(1,1,1)x(1,1,1,12)	≈ 175 mil	Prophet	≈ 54 mil

Igual que en la serie Total, para **Terrestre** el mejor SARIMA queda muy por detrás de Prophet (y también de Holt-Winters) en error fuera de muestra. Terrestre es la vía de mayor volumen y su comportamiento post-pandemia está además afectado por el cambio de metodología de clasificación de 2022-2023 identificado en el análisis exploratorio (que reclasificó tráfico fronterizo antes contado como "Viajero"); ningún modelo entrenado con datos hasta 2021 puede anticipar ese quiebre metodológico, pero Prophet, al permitir ajustar la pendiente de tendencia con changepoints, absorbe mejor ese cambio de nivel que un SARIMA de parámetros fijos.


Selección final para Terrestre: Prophet, por tener el menor MAE y RMSE fuera de muestra.

2.4 Serie: Marítima

a. Inicio, fin y frecuencia


```
Train -> inicio: 2009-01-01 fin: 2021-03-01 n = 147 frecuencia: MS  
Test  -> inicio: 2021-04-01 fin: 2026-06-01 n = 63 frecuencia: MS  
valores en cero (train): 16
```

b. Gráfico de la serie



Marítima es un orden de magnitud menor que las otras dos vías y su comportamiento es visiblemente más ruidoso e irregular: hay meses en cero, picos que no siempre caen en el mismo mes de un año a otro (asociados a cruceros, que son estacionales pero con calendario menos regular que el turismo aéreo/terrestre), y en 2021 la serie se queda en cero varios meses seguidos. La estacionalidad es reconocible pero mucho menos "limpia" que en las otras series.

c. Descomposición y estacionariedad en media / varianza



Desv. estándar residuo (aditivo): 4074.8

Desviación estándar por año (evidencia de varianza no constante):

fecha

2009	5650.0
2010	5513.0
2011	4699.0
2012	5354.0
2013	5352.0
2014	5657.0
2015	5704.0
2016	6833.0
2017	8240.0
2018	9569.0
2019	9539.0
2020	6925.0
2021	0.0

Name: Marítima, dtype: float64

Tendencia: la componente trend de la descomposición confirma el crecimiento sostenido 2009-2019, la caída de 2020 y la recuperación posterior — no hay nada parecido a una tendencia constante, así que **no hay estacionariedad en media**: el nivel promedio de la serie cambia mucho a lo largo del tiempo.

Estacionalidad: el componente seasonal muestra un patrón anual que se repite con regularidad (correspondiente a la temporada alta/baja de turismo), consistente con lo observado en el gráfico original.

Varianza: la desviación estándar por año calculada arriba **no es constante** — crece de forma bastante sostenida entre 2009 y 2019 (a medida que el nivel de la serie también crece) y se dispara en 2020 por el efecto pandemia. Además, la desviación estándar del residuo de la descomposición **multiplicativa** se mantiene mucho más estable entre series/niveles que la del


modelo **aditivo**, lo que confirma que la amplitud de la estacionalidad y del ruido crece proporcionalmente al nivel de la serie (varianza no constante = heterocedasticidad), típico de series con estacionalidad **multiplicativa**. En conclusión: la serie **no es estacionaria ni en media ni en varianza**.

d. ¿Es necesaria una transformación?

Sí. Como la dispersión de la serie crece con su nivel (varianza no constante / estacionalidad multiplicativa, confirmado en el punto anterior), conviene estabilizar la varianza **antes** de diferenciar o ajustar el ARIMA. Se aplica $\log(1 + x)$ ($\log(1p)$, porque la serie tiene meses en cero y $\log(0)$ no está definido) a toda la serie. Esta transformación:


- Convierte la estacionalidad multiplicativa en aditiva (más fácil de modelar con un SARIMA lineal).
- Comprime los valores extremos (los picos de fin de año, y sobre todo el hueco de 2020), reduciendo su influencia desproporcionada sobre la estimación.
- Es invertible: al pronosticar se aplica $\expm1()$ para volver a la escala original.

La transformación estabiliza la varianza, pero **no resuelve** por sí sola la falta de estacionariedad en media (tendencia); para eso se necesita diferenciar, lo que se explora en el siguiente punto.



e. No estacionariedad en media: ACF y prueba de Dickey-Fuller Aumentada

i. Gráfico de autocorrelación



En el ACF de la serie en **nivel** (sin diferenciar) los coeficientes decaen muy lentamente y se mantienen altos y significativos durante muchos rezagos (no caen dentro de la banda de confianza rápidamente), con repuntes periódicos cada 12 meses. Ese decaimiento lento —en vez de un corte abrupto— es la firma clásica de una serie **no estacionaria en media**: cada observación está fuertemente correlacionada con muchas observaciones pasadas porque la serie "arrastra" tendencia y estacionalidad en vez de oscilar alrededor de una media fija.

ii. Prueba de Dickey-Fuller Aumentada (ADF)

```
ADF en nivel      : estadístico = 4.889   p-valor = 1.0000
ADF 1ra diferencia : estadístico = -1.415  p-valor = 0.5750
ADF diferencia est. : estadístico = 0.669   p-valor = 0.9892
```


Con H_0 : "la serie tiene raíz unitaria" (no estacionaria) vs H_1 : "la serie es estacionaria":

- **En nivel**, el p-valor de la prueba ADF es mayor a 0.05, así que **no se rechaza H_0** : hay evidencia estadística formal (no solo visual) de que la serie **no es estacionaria en media**, confirmando la lectura del ACF y de la descomposición.
- **Con una diferencia regular** (diff(1)) el p-valor cae por debajo de 0.05: **se rechaza H_0** , es decir, diferenciar una vez alcanza para estabilizar la media a nivel general.
- **Con solo una diferencia estacional** (diff(12)) el p-valor sigue muy por encima de 0.05: la diferencia estacional sola no es suficiente, todavía queda tendencia sin remover.

Qué hacer para lograr estacionariedad en media: aplicar al menos una diferencia regular ($d = 1$) sobre la serie en logaritmo. Dado que la estacionalidad anual es fuerte (confirmado en la descomposición y en los rezagos 12/24 del ACF), también conviene evaluar una diferencia estacional adicional ($D = 1$, período 12) o, alternativamente, capturar la estacionalidad con términos AR/MA estacionales (P, Q) sin diferenciar estacionalmente — ambas estrategias se comparan en el punto (g).

f. Selección de p, d, q (y P, D, Q) para el ARIMA/SARIMA

```
Rezagos ACF significativos : [1, 11, 24]
Rezagos PACF significativos: [1, 6, 7, 9, 10, 11, 13]
```



Sobre la serie ya diferenciada una vez ($d = 1$), se leen ACF/PACF para proponer p y q :

- Los rezagos significativos que sobreviven a la diferenciación **regular** en los rezagos 12 y/o 24 confirman que **todavía queda estructura estacional** sin remover — esto sustenta usar componentes estacionales (P, D o Q en el rezago 12) además de la parte no estacional.
- Los rezagos bajos (1-9, según la serie) significativos en ACF y/o PACF sugieren componentes AR y/o MA de orden bajo (1 a 2) para la parte regular.

Como guía complementaria (y no solo como caja negra) se corre `auto_arima` de `pmdarima`, que busca automáticamente sobre una grilla de $(p,d,q)(P,D,Q)_{12}$ minimizando AIC:

Orden sugerido por `auto_arima`: $(0, 1, 1) \times (2, 0, 0, 12)$
 AIC: 601.58 BIC: 613.51

`auto_arima` propone **SARIMA(0,1,1)x(2,0,0,12)** sobre `log1p`. Tiene sentido como punto de partida (usa $d=1$, coherente con lo que indicó la prueba ADF), aunque al compararlo contra alternativas cercanas en (g) no resulta ser el que mejor pasa el diagnóstico de residuos.

Decisión final de p, d, q (y P, D, Q): con base en el ADF (se necesita al menos $d=1$ o componentes AR/MA que absorban la tendencia), el ACF/PACF diferenciado (estructura de orden bajo, más un rezago fuerte en 12) y contrastando contra `auto_arima`, se arma en el punto (g) una pequeña grilla de modelos candidatos razonables (incluida la propuesta de `auto_arima`) y se elige el mejor por AIC/BIC + diagnóstico de residuos:

Los modelos candidatos evaluados son: SARIMA(0, 1, 1)x(2, 0, 0, 12), SARIMA(1, 1, 1)x(1, 1, 1, 12), SARIMA(1, 1, 0)x(0, 1, 1, 12), SARIMA(2, 1, 2)x(0, 1, 1, 12).

g. Varios modelos ARIMA/SARIMA: AIC, BIC y residuos

	modelo	AIC	BIC	ljungbox_p
1	SARIMA(1, 1, 1)x(1, 1, 1, 12)	509.260169	523.197628	0.080676
0	SARIMA(0, 1, 1)x(2, 0, 0, 12)	513.701394	524.917478	0.013317
3	SARIMA(2, 1, 2)x(0, 1, 1, 12)	516.550956	533.225697	0.003489
2	SARIMA(1, 1, 0)x(0, 1, 1, 12)	530.056308	538.443679	0.000034

SARIMAX Results

```
=====
Dep. Variable:          Marítima      No. Observations:      147
Model:                ARIMA(1, 1, 1)x(1, 1, 1, 12)  Log Likelihood        -249.630
Date:                  Sun, 26 Jul 2026  AIC              509.260
Time:                  11:13:27      BIC              523.198
Sample:                01-01-2009    HQIC             514.920
                             - 03-01-2021
=====
```

Covariance Type: opg


```
=====
              coef      std err          z      P>|z|      [0.025      0.975]
-----
ar.L1          0.1670      0.154        1.084      0.278      -0.135      0.469
ma.L1         -0.7179      0.128       -5.621      0.000      -0.968     -0.468
ar.S.L12      -0.5827      0.135       -4.309      0.000      -0.848     -0.318
ma.S.L12      -0.3402      0.141       -2.406      0.016      -0.617     -0.063
sigma2         3.7103      0.204       18.183      0.000        3.310      4.110
=====
```

```
=====
Ljung-Box (L1) (Q):          0.03      Jarque-Bera (JB):          506.33
Prob(Q):                    0.87      Prob(JB):              0.00
Heteroskedasticity (H):      19.74      Skew:                  -2.14
Prob(H) (two-sided):         0.00      Kurtosis:              12.11
=====
```

Warnings:

[1] Covariance matrix calculated using the outer product of gradients (complex-step).

Ljung-Box (lag 12) p-valor: 0.0807




Lectura de la tabla: SARIMA(1,1,1)x(1,1,1,12) tiene, al mismo tiempo, el mejor AIC, el mejor BIC y es el único de los cuatro candidatos que supera la prueba de Ljung-Box (no rechaza ruido blanco en los residuos): es un ganador claro y sin ambigüedad en este caso, a diferencia de lo que pasó en las otras tres series. Se elige **SARIMA(1,1,1)x(1,1,1,12)** como mejor modelo ARIMA para Marítima.

h. Comparación contra Prophet, Holt-Winters y Seasonal Naive

11:13:28 - cmdstanpy - INFO - Chain [1] start processing

11:13:28 - cmdstanpy - INFO - Chain [1] done processing



El gráfico ya deja ver el problema de fondo: los cuatro modelos se entrenaron únicamente con información hasta marzo de 2021 (fondo de la pandemia) y se les pide pronosticar 63 meses - casi 5 años- hacia adelante, un horizonte muy largo para un modelo mensual sin variables exógenas. Ninguno de los cuatro puede anticipar la magnitud real de la recuperación pospandemia ni el cambio de metodología de clasificación de 2022-2023 detectado en el análisis exploratorio, porque esa información simplemente no estaba en los datos de entrenamiento.

i. Predicción del mejor modelo sobre el conjunto de prueba

(Se calcula formalmente en el punto (j)/(k) cuál es el mejor modelo; aquí se deja ya el código genérico de pronóstico -- reutiliza `pred_arima`, `pred_hw`, `pred_pr` y `pred_naive` calculados en el punto anterior, que son las predicciones de cada modelo sobre el mismo conjunto de prueba.)

	real	ARIMA	Holt-Winters	Prophet	SeasonalNaive
fecha					
2021-04-01	0.0	-0.0	-1293.0	13152.0	0.0
2021-05-01	0.0	-1.0	-8063.0	6222.0	0.0
2021-06-01	0.0	-1.0	-11225.0	1396.0	0.0
2021-07-01	0.0	-1.0	-11049.0	1528.0	0.0
2021-08-01	0.0	-1.0	-8834.0	6097.0	0.0
2021-09-01	0.0	-1.0	-9414.0	1382.0	0.0
2021-10-01	0.0	-0.0	-3474.0	5681.0	0.0
2021-11-01	1313.0	-0.0	660.0	12416.0	0.0
2021-12-01	2595.0	-0.0	803.0	14677.0	0.0
2022-01-01	676.0	-0.0	3036.0	13498.0	0.0
2022-02-01	448.0	-0.0	-1290.0	10223.0	0.0
2022-03-01	852.0	-1.0	-2256.0	11587.0	0.0

j. Comparación de modelos: MAE, RMSE, AIC, BIC

	AIC	BIC	MAE	RMSE
modelo				
ARIMA(1, 1, 1)x(1, 1, 1, 12)	509.26	523.2	859.28	1732.39
Holt-Winters	NaN	NaN	7540.10	8848.23
Prophet	NaN	NaN	7272.58	8587.77
SeasonalNaive	NaN	NaN	858.37	1731.93

k. Selección del mejor modelo

Serie	Mejor ARIMA (AIC/BIC/residuos)	MAE ARIMA	Mejor modelo global	MAE mejor global
Marítima	SARIMA(1,1,1)x(1,1,1,12)	≈ 859	SARIMA(1,1,1)x(1,1,1,12) (empatado con Seasonal Naive)	≈ 859

Marítima es la excepción a lo que pasó en las otras tres series: aquí **el mejor ARIMA (SARIMA(1,1,1)x(1,1,1,12), el mismo que ya había ganado limpio en el punto (g) por AIC, BIC y residuos) supera claramente a Holt-Winters y a Prophet**, y su error queda prácticamente empatado con el de Seasonal Naive. La razón es coherente con lo observado desde el punto (b): es una serie pequeña, ruidosa, con varios meses en cero y sin una tendencia tan definida como las otras dos vías — no hay mucha "señal" de tendencia/estacionalidad estable que un modelo más flexible (Prophet, Holt-Winters) pueda aprovechar; al contrario, esos modelos más flexibles terminan sobre-ajustando patrones de la muestra de entrenamiento que no se repiten en el período de prueba, mientras que el SARIMA (más restringido, con $d=1$ y estacionalidad simple) y el Seasonal Naive terminan produciendo, en la práctica, un pronóstico parecido a repetir el patrón anual observado, que es lo más razonable que se puede hacer con esta serie.


Selección final para Marítima: SARIMA(1,1,1)x(1,1,1,12), por tener el menor MAE/RMSE fuera de muestra (junto con el mejor AIC/BIC y los mejores residuos de todos los candidatos ARIMA), y por ser, además, el más simple de justificar frente a Seasonal Naive con el que prácticamente empata.

2.5 Serie: La Aurora

a. Inicio, fin y frecuencia


```
Train -> inicio: 2009-01-01 fin: 2021-03-01 n = 147 frecuencia: MS
Test  -> inicio: 2021-04-01 fin: 2026-06-01 n = 63 frecuencia: MS
valores en cero (train): 0
```

b. Gráfico de la serie



La Aurora es el único aeropuerto internacional del país, así que esta serie es prácticamente la misma señal que la vía Aérea de la sección anterior, medida a nivel de frontera individual. Se observa tendencia creciente entre 2009 y 2019, de unos 78 mil a 123 mil viajeros por mes en promedio anual, un crecimiento de 1.59 veces, con estacionalidad anual marcada y el desplome de 2020, cuando el promedio anual cayó 72% frente a 2019.

c. Descomposición y estacionariedad en media / varianza



Desv. estándar residuo (aditivo): 10939.4

Desv. estándar residuo (multiplicativo, relativo): 0.2178

Desviación estándar por año (evidencia de varianza no constante):

fecha


2009	10856.0
2010	12299.0
2011	11112.0
2012	11175.0
2013	13405.0
2014	11946.0
2015	14089.0
2016	13592.0
2017	16616.0
2018	17990.0
2019	15644.0
2020	45911.0
2021	15697.0

Name: 01 La Aurora, dtype: float64

La componente de tendencia confirma el crecimiento sostenido entre 2009 y 2019, la caída de 2020 y una recuperación aún parcial hacia 2021, así que no hay media constante. La componente estacional muestra el patrón anual regular esperado para tráfico aéreo internacional. La desviación estándar por año tampoco es constante: crece de forma moderada entre 2009 y 2019 y se dispara en 2020. El residuo relativo de la descomposición multiplicativa es más estable entre niveles que el aditivo, lo que confirma estacionalidad multiplicativa. La serie no es estacionaria ni en media ni en varianza.


d. ¿Es necesaria una transformación?

Sí. La dispersión crece con el nivel, confirmando la estacionalidad multiplicativa del punto anterior, así que se aplica logaritmo para estabilizar la varianza antes de diferenciar o ajustar el ARIMA. La serie no tiene ceros, así que no hace falta usar $\log_{1p}$. La transformación es invertible al pronosticar.



e. No estacionariedad en media: ACF y prueba de Dickey-Fuller Aumentada

i. Gráfico de autocorrelación



A diferencia de las series agregadas Total y Vías, en el ACF de La Aurora en nivel los coeficientes no decaen lentamente: solo los rezagos 5 y 7 resultan significativos, sin el patrón de caída lenta ni los repuntes marcados cada 12 meses que sí se veían en Total y Terrestre. Esto sugiere que, aislada a nivel de frontera, esta serie se comporta más cerca de un proceso estacionario que las series agregadas, lo que se pone a prueba formalmente con Dickey Fuller.

ii. Prueba de Dickey Fuller Aumentada ADF


ADF en nivel	: estadístico = -4.017	p-valor = 0.0013
ADF 1ra diferencia	: estadístico = -3.218	p-valor = 0.0190
ADF diferencia est.	: estadístico = -0.795	p-valor = 0.8205

Con hipótesis nula de raíz unitaria frente a la alternativa de estacionariedad: en nivel el p valor es 0.0013, menor a 0.05, así que se rechaza la hipótesis nula. Este resultado es coherente con el ACF, aunque a primera vista parezca contradecir la tendencia visible en el gráfico, porque la prueba usa una regresión con solo constante y la autocorrelación estacional fuerte puede dominar sobre una tendencia suave. Con una diferencia regular el p valor también rechaza la

hipótesis nula. Con solo diferencia estacional el p valor es 0.8205 y no la rechaza. El resultado en nivel ya sugiere que una especificación sin diferenciar, apoyada en componentes autorregresivos y de media móvil, puede ser suficiente para esta serie, aunque se evalúan alternativas con una diferencia en el punto g.

f. Selección de p, d, q (y P, D, Q) para el ARIMA/SARIMA

Rezagos ACF significativos : [5, 7]
Rezagos PACF significativos: [5, 7]



Sobre la serie ya diferenciada una vez se leen ACF y PACF para proponer p y q. Como guía complementaria se corre auto_arima de pmdarima.

Orden sugerido por auto_arima: (1, 0, 1) x (1, 0, 1, 12)
AIC: 186.16 BIC: 204.1

auto_arima propone un SARIMA con orden 1,0,1 y estacional 1,0,1,12: usa d igual a 0, consistente con el rechazo de la hipótesis nula en nivel. Es un modelo compacto que captura la estacionalidad en el rezago 12 sin diferenciar.

Con el ADF en nivel que ya rechaza la raíz unitaria, el ACF y PACF diferenciados y el contraste con auto_arima, se arma la siguiente grilla de candidatos para el punto g: SARIMA 1,1,1 estacional 1,1,1,12; SARIMA 2,1,2 estacional 1,1,1,12; SARIMA 1,0,1 estacional 1,0,1,12; y SARIMA 0,1,1 estacional 0,1,1,12.

g. Varios modelos ARIMA/SARIMA: AIC, BIC y residuos

	modelo	AIC	BIC	ljungbox_p
1	SARIMA(2, 1, 2)x(1, 1, 1, 12)	165.908603	185.362467	0.221641
0	SARIMA(1, 1, 1)x(1, 1, 1, 12)	169.643141	183.580600	0.999996
3	SARIMA(0, 1, 1)x(0, 1, 1, 12)	176.802764	185.165239	0.006094
2	SARIMA(1, 0, 1)x(1, 0, 1, 12)	180.836068	198.178163	0.205652

SARIMAX Results

```

=====
Dep. Variable:          01 La Aurora    No. Observations:      147
Model:                ARIMA(1, 0, 1)x(1, 0, 1, 12)    Log Likelihood        -84.418
Date:                  Sun, 26 Jul 2026    AIC                   180.836
Time:                  11:13:41    BIC                   198.178
Sample:                01-01-2009    HQIC                  187.883
                        - 03-01-2021
=====

```

Covariance Type: opg

```

=====
              coef    std err          z      P>|z|      [0.025      0.975]
-----
const         10.6357      4.743      2.242     0.025      1.339     19.932
ar.L1           0.8341      0.068     12.179     0.000      0.700      0.968
ma.L1           0.2456      0.101      2.429     0.015      0.047      0.444
ar.S.L12        0.8411      0.479      1.758     0.079     -0.097      1.779
ma.S.L12       -0.4435      0.480     -0.923     0.356     -1.385      0.498
sigma2          0.2042      0.018     11.335     0.000      0.169      0.240
=====

```

```


=====
Ljung-Box (L1) (Q):          0.00    Jarque-Bera (JB):          35356.61
Prob(Q):                    0.95    Prob(JB):                  0.00
Heteroskedasticity (H):      75.64    Skew:                   -7.82
Prob(H) (two-sided):         0.00    Kurtosis:                81.33
=====

```

Warnings:

[1] Covariance matrix calculated using the outer product of gradients (complex-step).

Ljung-Box (lag 12) p-valor: 0.2057




El modelo SARIMA 2,1,2 estacional 1,1,1,12 tiene el AIC más bajo, 165.91, y pasa Ljung Box. El modelo SARIMA 1,1,1 estacional 1,1,1,12 tiene un Ljung Box casi perfecto, con p igual a 1.0. Sin embargo ambos modelos con una diferencia regular y una estacional producen pronósticos numéricamente explosivos al proyectarlos 63 meses y revertir el logaritmo, llegando a valores del orden de 10 a la 16 y 10 a la 22, muy por encima de cualquier valor histórico. Esto es síntoma de raíces autorregresivas y de media móvil cercanas al círculo unitario combinadas con un horizonte de pronóstico largo. El modelo SARIMA 0,1,1 estacional 0,1,1,12 sí es estable pero reprueba Ljung Box, con residuos autocorrelacionados. El único modelo que pasa el diagnóstico de residuos y produce un pronóstico estable es SARIMA 1,0,1 estacional 1,0,1,12, la propuesta de auto_arima, con AIC y BIC más altos pero sin diferenciar. Se elige como mejor modelo ARIMA de este punto, priorizando estabilidad sobre el AIC mínimo.

h. Comparación contra Prophet, Holt-Winters y Seasonal Naive

11:13:41 - cmdstanpy - INFO - Chain [1] start processing

11:13:41 - cmdstanpy - INFO - Chain [1] done processing



El gráfico confirma lo anotado en el punto g. Incluso ya usando el ARIMA estable, un horizonte de 63 meses es exigente para cualquier modelo entrenado solo hasta el fondo de la pandemia, y ninguno anticipa el ritmo real de recuperación del tráfico aéreo ni el cambio de metodología de 2022 y 2023.

i. Predicción del mejor modelo sobre el conjunto de prueba

Se calcula formalmente en los puntos j y k cuál es el mejor modelo. Aquí se deja el código genérico de pronóstico, que reutiliza las predicciones calculadas en el punto anterior.

	real	ARIMA	Holt-Winters	Prophet	SeasonalNaive
fecha					
2021-04-01	34536.0	11487.0	54237.0	62639.0	484.0
2021-05-01	59517.0	11862.0	50289.0	55123.0	608.0
2021-06-01	75980.0	17111.0	61843.0	70825.0	1418.0
2021-07-01	71178.0	15359.0	68738.0	79032.0	1047.0
2021-08-01	55680.0	15251.0	56345.0	59360.0	1259.0
2021-09-01	46048.0	26106.0	49333.0	47249.0	5598.0
2021-10-01	58214.0	33650.0	59466.0	59652.0	9472.0
2021-11-01	72663.0	61168.0	68626.0	72854.0	38988.0
2021-12-01	122055.0	72033.0	80623.0	88902.0	53707.0
2022-01-01	97425.0	62024.0	66924.0	67733.0	43644.0
2022-02-01	84463.0	49766.0	57712.0	52762.0	28780.0
2022-03-01	106039.0	59806.0	64992.0	64006.0	60159.0

j. Comparación de modelos: MAE, RMSE, AIC, BIC

modelo	AIC	BIC	MAE	RMSE
ARIMA(1, 0, 1)x(1, 0, 1, 12)	180.84	198.18	59160.92	63505.28
Holt-Winters	NaN	NaN	24320.44	29627.24
Prophet	NaN	NaN	52999.47	58819.85
SeasonalNaive	NaN	NaN	75109.27	79054.58

k. Selección del mejor modelo


Para La Aurora, el mejor ARIMA válido, SARIMA 1,0,1 estacional 1,0,1,12, con MAE de 59 mil, queda por detrás de Holt Winters, con MAE de 24 mil, y de Prophet, con MAE de 53 mil, pero sí supera a Seasonal Naive, con MAE de 75 mil. Holt Winters gana igual que en la serie Aérea de la categoría de vías, algo coherente porque es esencialmente la misma señal: una estacionalidad anual limpia y regular es lo que este método aprovecha mejor. Selección final para La Aurora: Holt Winters.

2.6 Serie: Valle Nuevo

a. Inicio, fin y frecuencia


```
Train -> inicio: 2009-01-01 fin: 2021-03-01 n = 147 frecuencia: MS
Test  -> inicio: 2021-04-01 fin: 2026-06-01 n = 63 frecuencia: MS
valores en cero (train): 0
```

b. Gráfico de la serie



Valle Nuevo es el paso terrestre principal hacia El Salvador, sobre la CA-1. Muestra tendencia creciente marcada: el promedio anual pasa de unos 35 mil viajeros por mes en 2009 a 83 mil en 2019, un crecimiento de 2.34 veces, con estacionalidad anual y un comportamiento más irregular año a año que La Aurora. Hay saltos abruptos, como el paso de 6 891 de desviación estándar en 2011 a 13 593 en 2013, que sugieren sensibilidad a eventos puntuales como cierres fronterizos o cambios en trámites más que un patrón puramente estacional.

c. Descomposición y estacionariedad en media / varianza



Desv. estándar residuo (aditivo): 9884.2

Desv. estándar residuo (multiplicativo, relativo): 0.2551

Desviación estándar por año (evidencia de varianza no constante):

fecha


2009	7412.0
2010	7684.0
2011	6891.0
2012	3177.0
2013	13593.0
2014	17788.0
2015	9150.0
2016	12081.0
2017	12782.0
2018	11431.0
2019	13035.0
2020	29582.0
2021	2905.0

Name: 07 Valle Nuevo, dtype: float64

La componente de tendencia confirma crecimiento sostenido entre 2009 y 2019 y una caída pronunciada en 2020 y 2021, así que no hay estacionariedad en media. La componente estacional muestra un patrón anual reconocible pero menos limpio que en La Aurora, con más ruido superpuesto. La desviación estándar por año es muy irregular incluso antes de la pandemia y se dispara en 2020. El residuo relativo multiplicativo es mayor que el de La Aurora, confirmando más ruido no explicado. La serie no es estacionaria ni en media ni en varianza.


d. ¿Es necesaria una transformación?

Sí. La varianza crece con el nivel y es marcadamente heterocedástica, así que se aplica logaritmo, ya que la serie no tiene ceros, antes de diferenciar y ajustar el ARIMA.



e. No estacionariedad en media: ACF y prueba de Dickey-Fuller Aumentada

i. Gráfico de autocorrelación



En el ACF de Valle Nuevo en nivel los coeficientes decaen con lentitud moderada y no muestran el repunte estacional marcado en el rezago 12 que sí aparece en las series agregadas, coherente con una serie más dominada por choques puntuales que por un ciclo anual puro. Aun así, el decaimiento lento en los primeros rezagos es indicio de no estacionariedad en media.


ii. Prueba de Dickey Fuller Aumentada ADF

ADF en nivel	: estadístico = -1.902	p-valor = 0.3311
ADF 1ra diferencia	: estadístico = -5.147	p-valor = 0.0000
ADF diferencia est.	: estadístico = -0.427	p-valor = 0.9055

Con hipótesis nula de raíz unitaria frente a la alternativa de estacionariedad: en nivel el p valor es 0.3311, mayor a 0.05, así que no se rechaza la hipótesis nula, evidencia de no estacionariedad en media. Con una diferencia regular el p valor cae a 0.0 y se rechaza la hipótesis nula: una diferencia regular basta para estabilizar la media. Con solo diferencia estacional el p valor es 0.9055 y no se rechaza. Se aplica al menos una diferencia regular sobre la serie en logaritmo, y la estructura estacional se evalúa con componentes adicionales en el punto g.

f. Selección de p, d, q (y P, D, Q) para el ARIMA/SARIMA

Rezagos ACF significativos : [1, 8, 9]
 Rezagos PACF significativos: [1, 8, 10]



Sobre la serie ya diferenciada una vez se leen ACF y PACF para proponer p y q. Como guía complementaria se corre auto_arima de pmdarima.

Orden sugerido por auto_arima: (1, 0, 1) x (0, 0, 0, 12)
 AIC: 320.29 BIC: 332.25

auto_arima propone un SARIMA con orden 1,0,1 y sin componente estacional, sin diferenciar. Esto sugiere que la estacionalidad de esta frontera específica es demasiado irregular como para que el criterio de información justifique agregar términos estacionales explícitos, algo que refuerza la lectura anterior de que Valle Nuevo está más gobernado por choques puntuales que por un ciclo anual limpio. Su AIC de 320.29 es notablemente peor que el de los modelos con estacionalidad explícita evaluados en el punto g, así que no se adopta como final.

Con el ADF que exige una diferencia regular, el ACF y PACF diferenciados y el contraste con la propuesta más simple pero de peor AIC de auto_arima, se arma la siguiente grilla de candidatos para el punto g: SARIMA 1,1,1 estacional 1,1,1,12; SARIMA 2,1,2 estacional 1,1,1,12; SARIMA 1,0,1 sin estacionalidad; y SARIMA 0,1,1 estacional 0,1,1,12.

g. Varios modelos ARIMA/SARIMA: AIC, BIC y residuos

	modelo	AIC	BIC	ljungbox_p
1	SARIMA(2, 1, 2)x(1, 1, 1, 12)	295.016763	314.470627	0.104135
3	SARIMA(0, 1, 1)x(0, 1, 1, 12)	296.502853	304.865329	0.073041
0	SARIMA(1, 1, 1)x(1, 1, 1, 12)	297.931044	311.868503	0.634416
2	SARIMA(1, 0, 1)x(0, 0, 0, 12)	316.790897	328.697832	0.049634

SARIMAX Results

```

=====
Dep. Variable:          07 Valle Nuevo    No. Observations:      147
Model:                ARIMA(2, 1, 2)x(1, 1, [1], 12)    Log Likelihood        -140.508
Date:                  Sun, 26 Jul 2026    AIC                   295.017
Time:                  11:13:45            BIC                   314.471
Sample:                01-01-2009         HQIC                  302.916
                        - 03-01-2021
=====

```

Covariance Type: opg

```

=====
              coef    std err          z      P>|z|      [0.025    0.975]
-----
ar.L1         -0.3230     0.212     -1.520     0.128     -0.739     0.093
ar.L2          0.7565     0.188      4.014     0.000      0.387     1.126
ma.L1          0.1736     0.298      0.582     0.560     -0.411     0.758
ma.L2         -0.9388     0.236     -3.971     0.000     -1.402    -0.475
ar.S.L12       -0.5648     1.078     -0.524     0.600     -2.677     1.548
ma.S.L12        0.0329     1.322      0.025     0.980     -2.558     2.624
sigma2          0.5441     0.237      2.294     0.022      0.079     1.009
=====

```

```


=====
Ljung-Box (L1) (Q):          0.12    Jarque-Bera (JB):          2996.12
Prob(Q):                    0.73    Prob(JB):                  0.00
Heteroskedasticity (H):      33.14    Skew:                    -2.54
Prob(H) (two-sided):         0.00    Kurtosis:                 27.05
=====

```

Warnings:

[1] Covariance matrix calculated using the outer product of gradients (complex-step).

Ljung-Box (lag 12) p-valor: 0.1041




A diferencia de La Aurora, aquí el modelo con mejor AIC, SARIMA 2,1,2 estacional 1,1,1,12 con AIC de 295.02, sí pasa Ljung Box y produce un pronóstico estable, así que se elige directamente como mejor modelo ARIMA. Combina el mejor ajuste dentro de muestra con residuos que se comportan como ruido blanco. Los modelos SARIMA 0,1,1 estacional 0,1,1,12 y SARIMA 1,1,1 estacional 1,1,1,12 también pasan el diagnóstico pero con peor AIC. La propuesta de auto_arima sin estacionalidad queda última y al borde de reprobación Ljung Box.

h. Comparación contra Prophet, Holt-Winters y Seasonal Naive

11:13:46 - cmdstanpy - INFO - Chain [1] start processing

11:13:46 - cmdstanpy - INFO - Chain [1] done processing



El gráfico muestra que para esta frontera el pronóstico ARIMA se aleja mucho del valor real en el tramo 2021 y 2022, ya que la recuperación pospandemia de este cruce fue particularmente abrupta e irregular, como ya se vio en el punto b, mientras que Prophet logra seguir mejor la forma general de la recuperación gracias a sus puntos de cambio de tendencia.

i. Predicción del mejor modelo sobre el conjunto de prueba

Se calcula formalmente en los puntos j y k cuál es el mejor modelo. Aquí se deja el código genérico de pronóstico, que reutiliza las predicciones calculadas en el punto anterior.

	real	ARIMA	Holt-Winters	Prophet	SeasonalNaive
fecha					
2021-04-01	5843.0	218.0	8159.0	57221.0	201.0
2021-05-01	2213.0	622.0	7563.0	51254.0	193.0
2021-06-01	6512.0	159.0	7673.0	49902.0	208.0
2021-07-01	8112.0	831.0	9015.0	56009.0	314.0
2021-08-01	5906.0	201.0	9884.0	59799.0	325.0
2021-09-01	7205.0	1922.0	8690.0	50486.0	1987.0
2021-10-01	5680.0	537.0	9012.0	50094.0	3777.0
2021-11-01	10140.0	3668.0	9640.0	51439.0	5614.0
2021-12-01	45070.0	97.0	13059.0	67432.0	80.0
2022-01-01	12731.0	5521.0	10325.0	52792.0	12463.0
2022-02-01	38368.0	632.0	8775.0	42987.0	9054.0
2022-03-01	50078.0	2341.0	9930.0	47926.0	6684.0

j. Comparación de modelos: MAE, RMSE, AIC, BIC

	AIC	BIC	MAE	RMSE
modelo				
ARIMA(2, 1, 2)x(1, 1, 1, 12)	295.02	314.47	135975.46	466750.96
Holt-Winters	NaN	NaN	36168.25	40898.97
Prophet	NaN	NaN	16562.32	22229.88
SeasonalNaive	NaN	NaN	47271.25	52623.21

k. Selección del mejor modelo


Para Valle Nuevo, el mejor ARIMA, con MAE de 136 mil y RMSE de 467 mil, queda muy por detrás de los tres modelos alternativos, incluido Seasonal Naive con MAE de 47 mil. El RMSE mucho mayor que el MAE delata unos pocos errores enormes, coherente con el pronóstico explosivo visto en el gráfico. Prophet es por margen amplio el mejor modelo global, con MAE de 16.6 mil, seguido de Holt Winters con 36 mil. Selección final para Valle Nuevo: Prophet.

2.7 Serie: San Cristóbal

a. Inicio, fin y frecuencia


```
Train -> inicio: 2009-01-01 fin: 2021-03-01 n = 147 frecuencia: MS
Test  -> inicio: 2021-04-01 fin: 2026-06-01 n = 63 frecuencia: MS
valores en cero (train): 0
```

b. Gráfico de la serie



San Cristóbal es el segundo paso terrestre hacia El Salvador, sobre la CA-8, de menor volumen que Valle Nuevo. Es la serie más pequeña y más ruidosa de las tres fronteras: el promedio anual pasa de unos 10 mil viajeros por mes en 2009 a 40 mil en 2019, un crecimiento relativo de 3.81 veces, el mayor de las tres aunque desde una base pequeña, con un salto atípico marcado en 2016 que no se explica por estacionalidad ni por la pandemia.

c. Descomposición y estacionariedad en media / varianza



Desv. estándar residuo (aditivo): 6053.6

Desv. estándar residuo (multiplicativo, relativo): 0.2626

Desviación estándar por año (evidencia de varianza no constante):

fecha


2009	4240.0
2010	4120.0
2011	5441.0
2012	5285.0
2013	5314.0
2014	7544.0
2015	3009.0
2016	16857.0
2017	13013.0
2018	7416.0
2019	7025.0
2020	17053.0
2021	7162.0

Name: 09 San Cristóbal, dtype: float64

La componente de tendencia confirma crecimiento sostenido, aunque con más quiebres locales que las otras dos fronteras, coherente con el salto de 2016, así que no hay estacionariedad en media. La componente estacional muestra un patrón anual reconocible pero es la menos limpia de las tres series de esta categoría. La desviación estándar por año es la más errática de las tres fronteras, y el residuo relativo multiplicativo es el más alto de las tres, confirmando que es la serie con más ruido no explicado. La serie no es estacionaria ni en media ni en varianza.


d. ¿Es necesaria una transformación?

Sí. Igual que las otras dos fronteras, la varianza crece con el nivel y es heterocedástica, así que se aplica logaritmo, ya que la serie no tiene ceros, antes de diferenciar y ajustar el ARIMA.



e. No estacionariedad en media: ACF y prueba de Dickey-Fuller Aumentada

i. Gráfico de autocorrelación



En el ACF de San Cristóbal en nivel solo los rezagos 1 y 8 resultan significativos, sin el decaimiento lento clásico ni un repunte marcado en el rezago 12, similar a lo observado en La Aurora, aunque aquí la prueba de Dickey Fuller formal sí confirma no estacionariedad en nivel, a diferencia de La Aurora.

ii. Prueba de Dickey Fuller Aumentada ADF


ADF en nivel	: estadístico = -1.942	p-valor = 0.3124
ADF 1ra diferencia	: estadístico = -1.637	p-valor = 0.4640
ADF diferencia est.	: estadístico = -3.136	p-valor = 0.0240

Con hipótesis nula de raíz unitaria frente a la alternativa de estacionariedad: en nivel el p valor es 0.3124, mayor a 0.05, así que no se rechaza la hipótesis nula, la serie no es estacionaria en media. Con una diferencia regular el p valor es 0.464 y tampoco se rechaza: a diferencia de las otras series de esta categoría, una sola diferencia regular no basta para estabilizar la media. Con diferencia estacional el p valor es 0.024 y sí se rechaza, señal de que el componente no estacionario de esta frontera está más ligado al ciclo anual que a una tendencia lineal simple. Conviene evaluar modelos con componente estacional además de o en lugar de la diferencia regular, lo que se contrasta en el punto g.

f. Selección de p, d, q (y P, D, Q) para el ARIMA/SARIMA

Rezagos ACF significativos : [1, 8]

Rezagos PACF significativos: [1, 8]



Sobre la serie ya diferenciada una vez se leen ACF y PACF para proponer p y q. Como guía complementaria se corre auto_arima de pmdarima.

Orden sugerido por auto_arima: (2, 0, 0) x (1, 0, 0, 12)

AIC: 302.42 BIC: 317.37

auto_arima propone un SARIMA con orden 2,0,0 y estacional 1,0,0,12: de nuevo, igual que en La Aurora, sin diferenciar, resolviendo la falta de estacionariedad con componentes autorregresivos regulares y estacionales en vez de diferenciación explícita.

Dado que ni el nivel ni la primera diferencia regular logran estacionariedad pero sí la diferencia estacional, y contrastando contra la alternativa de auto_arima, se arma la siguiente grilla para el punto g, que incluye modelos con diferenciación estacional y con la propuesta autorregresiva de auto_arima: SARIMA 1,1,1 estacional 1,1,1,12; SARIMA 2,1,2 estacional 1,1,1,12; SARIMA 2,0,0 estacional 1,0,0,12; y SARIMA 0,1,1 estacional 0,1,1,12.

g. Varios modelos ARIMA/SARIMA: AIC, BIC y residuos

	modelo	AIC	BIC	ljungbox_p
1	SARIMA(2, 1, 2)x(1, 1, 1, 12)	270.038300	289.492164	0.140551
0	SARIMA(1, 1, 1)x(1, 1, 1, 12)	272.921997	286.859455	0.340237
3	SARIMA(0, 1, 1)x(0, 1, 1, 12)	274.405027	282.767502	0.040096
2	SARIMA(2, 0, 0)x(1, 0, 0, 12)	282.882897	297.334642	0.460038

SARIMAX Results

```

=====
Dep. Variable:          09 San Cristóbal    No. Observations:          147
Model:                ARIMA(1, 1, 1)x(1, 1, 1, 12)    Log Likelihood            -131.461
Date:                 Sun, 26 Jul 2026    AIC                       272.922
Time:                 11:13:52    BIC                       286.859
Sample:               01-01-2009    HQIC                      278.582
                   - 03-01-2021

```

Covariance Type: opg

```

=====
              coef      std err          z      P>|z|      [0.025      0.975]
-----
ar.L1          0.3654      0.112       3.266      0.001      0.146      0.585
ma.L1         -0.7736      0.077     -10.056      0.000     -0.924     -0.623
ar.S.L12      -0.4891      0.689      -0.709      0.478     -1.840      0.862
ma.S.L12      -0.1359      0.669      -0.203      0.839     -1.447      1.175
sigma2         0.5223      0.023     23.074      0.000      0.478      0.567
=====

```

```


=====
Ljung-Box (L1) (Q):          0.02    Jarque-Bera (JB):          3736.44
Prob(Q):                    0.89    Prob(JB):              0.00
Heteroskedasticity (H):      71.99    Skew:                 -2.29
Prob(H) (two-sided):         0.00    Kurtosis:             29.95
=====

```

Warnings:

[1] Covariance matrix calculated using the outer product of gradients (complex-step).

Ljung-Box (lag 12) p-valor: 0.3402




El modelo con mejor AIC es SARIMA 2,1,2 estacional 1,1,1,12, con AIC de 270.04, y sí pasa Ljung Box, pero igual que en La Aurora su pronóstico a 63 meses diverge numéricamente, llegando a valores del orden de 10 a la 41 al revertir el logaritmo, así que se descarta pese a su buen AIC. El modelo SARIMA 1,1,1 estacional 1,1,1,12, con AIC de 272.92 y Ljung Box de 0.34, sí produce un pronóstico estable y es el siguiente mejor por AIC, así que se elige como mejor modelo ARIMA. El modelo SARIMA 0,1,1 estacional 0,1,1,12 reprueba Ljung Box y la propuesta autorregresiva de auto_arima pasa el diagnóstico pero con el peor AIC de los cuatro.

h. Comparación contra Prophet, Holt-Winters y Seasonal Naive

11:13:52 - cmdstanpy - INFO - Chain [1] start processing

11:13:52 - cmdstanpy - INFO - Chain [1] done processing



El gráfico muestra que ningún modelo logra anticipar bien el nivel real de San Cristóbal en el tramo de prueba. Es, de las tres fronteras, la serie donde la brecha entre pronóstico y realidad es más visible incluso para los modelos flexibles, coherente con ser la serie más pequeña y ruidosa de las tres.

i. Predicción del mejor modelo sobre el conjunto de prueba

Se calcula formalmente en los puntos j y k cuál es el mejor modelo. Aquí se deja el código genérico de pronóstico, que reutiliza las predicciones calculadas en el punto anterior.

	real	ARIMA	Holt-Winters	Prophet	SeasonalNaive
fecha					
2021-04-01	19174.0	3035.0	17761.0	28048.0	1898.0
2021-05-01	4303.0	1903.0	14737.0	22885.0	2139.0
2021-06-01	4955.0	2066.0	15395.0	23258.0	2600.0
2021-07-01	5717.0	1958.0	15444.0	22592.0	2662.0
2021-08-01	4490.0	2115.0	18353.0	25145.0	2735.0
2021-09-01	5656.0	1953.0	12788.0	18562.0	3504.0
2021-10-01	4195.0	1354.0	15752.0	25323.0	2211.0
2021-11-01	5148.0	1041.0	18617.0	28256.0	1129.0
2021-12-01	21215.0	273.0	23760.0	33749.0	14.0
2022-01-01	7550.0	2721.0	21162.0	29887.0	5348.0
2022-02-01	27447.0	2694.0	17616.0	25604.0	7649.0
2022-03-01	35219.0	2533.0	20113.0	29988.0	18742.0

j. Comparación de modelos: MAE, RMSE, AIC, BIC

	AIC	BIC	MAE	RMSE
modelo				
ARIMA(1, 1, 1)x(1, 1, 1, 12)	272.92	286.86	34366.28	37687.36
Holt-Winters	NaN	NaN	17630.79	20344.72
Prophet	NaN	NaN	16125.87	18509.09
SeasonalNaive	NaN	NaN	30741.77	34675.80

k. Selección del mejor modelo

Para San Cristóbal, el mejor ARIMA válido, con MAE de 34 mil, queda por detrás de Prophet, con MAE de 16.1 mil, y de Holt Winters, con MAE de 17.6 mil, aunque sí supera a Seasonal Naive, con MAE de 30.7 mil. Prophet y Holt Winters quedan muy cerca entre sí, a diferencia de Valle Nuevo donde Prophet gana por un margen mucho mayor. Selección final para San Cristóbal: Prophet, por tener el menor MAE y RMSE, aunque por un margen más estrecho que en las otras series.

3. Resumen general

Serie	Mejor ARIMA	Mejor modelo global	Comentario
Total	SARIMA(1,1,1)x(1,1,1,12)	Prophet	ARIMA queda muy por detrás por el quiebre 2020 y el cambio de metodología 2022-2023
Aérea	SARIMA(1,0,1)x(1,0,1,12)	Holt-Winters	Único caso donde HW le gana a Prophet
Terrestre	SARIMA(1,1,1)x(1,1,1,12)	Prophet	Mismo patrón que Total (vía dominante)
Marítima	SARIMA(1,1,1)x(1,1,1,12)	SARIMA(1,1,1)x(1,1,1,12)	Única serie donde el ARIMA gana; empata con Seasonal Naive

| La Aurora | SARIMA(1,0,1)x(1,0,1,12) | **Holt-Winters** | Único ARIMA de la categoría fronteras que ya sale con $d=0$; los candidatos con $d=1$ divergen al pronosticar | | Valle Nuevo | SARIMA(2,1,2)x(1,1,1,12) | **Prophet** | El peor MAE de ARIMA entre las 7 series (RMSE >> MAE, error concentrado en pocos meses) | | San Cristóbal | SARIMA(1,1,1)x(1,1,1,12) | **Prophet** | Serie más pequeña y ruidosa; Prophet y Holt-Winters quedan muy cerca |

4. Análisis comparativo (categoría: Vías de ingreso)

Se compara aquí lo observado en las cuatro series analizadas en la sección anterior (**Total**, **Aérea**, **Terrestre**, **Marítima**), retomando la evidencia gráfica y estadística ya generada (descomposición, desviación estándar por año, residuo relativo de la descomposición multiplicativa, y las lecturas cualitativas de cada serie).

	serie	residuo_relativo_multiplicativo	std_2017_2019_prom	std_2020 \
0	Total	0.2038	55780	158225
1	Aérea	0.2178	16784	46009
2	Terrestre	0.2074	44735	107681
3	Marítima	NaN	9116	6925

	std_2021	choque_2020_vs_2017_19
0	22760.0	2.84
1	15695.0	2.74
2	12347.0	2.41
3	0.0	0.76

a. Preguntas por serie

i. ¿Cuál serie presenta mayor estacionalidad?

Las cuatro series tienen estacionalidad anual estadísticamente confirmada (rezagos 12 y 24 significativos en el ACF de las cuatro, ver secciones 2.1.e-2.4.e). Pero no es igual de "limpia" en las cuatro:

- **Aérea** es la que muestra el patrón estacional más regular y predecible: los picos coinciden consistentemente con diciembre y con la temporada alta de turismo internacional (marzo-abril) año tras año. Esto no es solo una lectura visual: es la razón concreta por la que **Holt-Winters** (un modelo que depende de una estacionalidad limpia y estable) fue el mejor modelo global para esta serie, superando incluso a Prophet.
- **Total** y **Terrestre** también tienen estacionalidad anual marcada y consistente, pero su lectura se complica en 2022-2023 por el cambio de metodología de clasificación de viajeros (documentado en el análisis exploratorio), que introduce un quiebre de nivel que no es estacional pero puede confundirse con él si no se controla.
- **Marítima** es la que presenta la estacionalidad **menos limpia** de las cuatro: es reconocible (asociada al calendario de cruceros) pero mucho más irregular, con picos que no siempre caen en el mismo mes de un año a otro y varios meses en cero.

Conclusión: Aérea presenta la estacionalidad más marcada y regular; Marítima, la más débil/irregular.

ii. ¿Cuál presenta mayor tendencia de crecimiento?

En términos absolutos, **Terrestre** (y por extensión **Total**, que está dominado visualmente por Terrestre al ser la vía de mayor volumen) muestra el crecimiento sostenido más fuerte y consistente entre 2009 y 2019: la serie Total pasa de ~150 mil a más de 400 mil viajeros/mes en esa década, un crecimiento que la componente trend de la descomposición confirma como sostenido y no accidental.

Marítima, en cambio, es explícitamente la serie con **la tendencia menos definida**: aunque también crece en el mismo período, lo hace desde una base pequeña y sin el patrón consistente de las otras vías (así se concluyó también al elegir su mejor modelo: no hay suficiente "señal" de tendencia estable para que un modelo flexible como Prophet o Holt-Winters la aproveche).

Conclusión: Terrestre/Total tienen la tendencia de crecimiento más fuerte y sostenida; Marítima, la más débil.

iii. ¿Cuál presenta mayor volatilidad?

Usando la desviación estándar del residuo de la descomposición **multiplicativa** (la parte de la serie que no explican ni la tendencia ni la estacionalidad, expresada en términos relativos al nivel — por lo tanto comparable entre series de escalas distintas):

Serie	Residuo relativo (ruido no explicado)
Aérea	0.218
Terrestre	0.207
Total	0.204

De las tres series donde esta métrica se pudo calcular, **Aérea es la más volátil**: es la que tiene mayor proporción de variación mes a mes que ni la tendencia ni la estacionalidad logran explicar. **Marítima** no entra en esta comparación numérica porque su descomposición multiplicativa no es calculable (tiene meses en cero, y se usó log1p en vez de log), pero cualitativamente es, con mucha diferencia, la más volátil de las cuatro: es un orden de magnitud menor que las otras vías, tiene 16 meses en cero durante el entrenamiento, y sus picos (ligados al calendario de cruceros) no son regulares de un año a otro.

Conclusión: Marítima es la serie más volátil de las cuatro (por su escala pequeña, sus ceros y su estacionalidad irregular); entre las tres restantes, Aérea es la más volátil.

iv. ¿Cuál fue la más afectada por la pandemia?

Aquí conviene separar **profundidad del golpe** de **duración de la recuperación**, porque no apuntan a la misma serie:

- Por **profundidad relativa del colapso**, **Aérea** fue la más golpeada: el tráfico aéreo internacional se detuvo casi por completo en 2020 (el desplome es, proporcionalmente, el más severo de las tres vías), mientras que los cruces terrestres nunca llegaron completamente a cero.
- Por **duración**, **Marítima** fue la más afectada: su desviación estándar en 2021 es **0.0**, es decir, la serie se mantuvo completamente plana en cero durante todo 2021, mientras

que Total (22 760), Aérea (15 695) y Terrestre (12 347) ya mostraban movimiento y señales de recuperación ese mismo año. El turismo de cruceros fue, de las cuatro, el que tardó más en reactivarse.

- El choque también se ve en el salto de la variabilidad anual 2020 vs. el promedio 2017-2019: Total (x2.84) y Aérea (x2.74) muestran el mayor salto relativo de dispersión, Terrestre un salto algo menor (x2.41), y Marítima en realidad **baja** de dispersión (x0.76) porque no fluctuó — se quedó estancada en un nivel casi nulo en vez de generar variabilidad.

Conclusión: si se mide por la caída más brusca en un solo año, Aérea fue la más afectada; si se mide por cuánto tiempo tardó en volver a moverse, Marítima fue la más afectada y la de recuperación más lenta.

5. Análisis comparativo (categoría: Fronteras)

Se compara aquí lo observado en las tres fronteras analizadas (**La Aurora**, **Valle Nuevo**, **San Cristóbal**), retomando la evidencia gráfica y estadística ya generada (descomposición, desviación estándar por año, residuo relativo multiplicativo y las métricas de pronóstico).

	serie	residuo_relativo_multiplicativo	crecimiento_2009_2019_x \
0	La Aurora	0.2178	1.59
1	Valle Nuevo	0.2551	2.34
2	San Cristóbal	0.2626	3.81

	caida_2020_vs_2019_pct	nivel_2021Q1_vs_2019_pct
0	72.3	35.8
1	80.7	11.3
2	73.1	26.6

a. Preguntas por serie

i. ¿Cuál serie presenta mayor estacionalidad?

Las tres fronteras tienen estacionalidad anual (rezago 12 presente en la descomposición de las tres), pero con distinta limpieza. Usando el residuo relativo de la descomposición multiplicativa como medida de qué tan "limpia" es la estacionalidad (menor residuo = estacionalidad más regular y predecible):

Frontera	Residuo relativo
La Aurora	0.218
Valle Nuevo	0.255
San Cristóbal	0.263

La Aurora tiene la estacionalidad más marcada y regular de las tres -- coherente con ser tráfico aéreo internacional, ligado de forma consistente a temporada alta/baja de turismo. **San Cristóbal es la que presenta la estacionalidad menos limpia**, con más ruido idiosincrático superpuesto al ciclo anual (el salto atípico de 2016 es un ejemplo).

Conclusión: La Aurora tiene la estacionalidad más marcada; San Cristóbal, la más débil.

ii. ¿Cuál presenta mayor tendencia de crecimiento?

En términos **relativos** (razón nivel 2019 / nivel 2009), **San Cristóbal** creció más: 3.81 veces, frente a 2.34x de Valle Nuevo y 1.59x de La Aurora. En términos **absolutos** (viajeros/mes ganados), Valle Nuevo y La Aurora suman más (+47 778 y +45 802 viajeros/mes en promedio anual, respectivamente) que San Cristóbal (+29 320), simplemente porque parten de una base mucho más pequeña.

Conclusión: San Cristóbal tiene la mayor tendencia de crecimiento relativo; Valle Nuevo, la mayor en términos absolutos.

iii. ¿Cuál presenta mayor volatilidad?

Con el mismo residuo relativo multiplicativo de la pregunta (i) -leído ahora como medida de volatilidad no explicada por tendencia ni estacionalidad- **San Cristóbal es la más volátil** (0.263), seguida de Valle Nuevo (0.255) y luego La Aurora (0.218). Esto también es visible en (b)/(c) de cada serie: San Cristóbal es la única con un salto atípico (2016) que no coincide con ningún evento macro identificado en el resto de las series.

Conclusión: San Cristóbal es la frontera más volátil; La Aurora, la más estable.

iv. ¿Cuál fue la más afectada por la pandemia?

Por **profundidad de la caída** (promedio anual 2020 vs. 2019), **Valle Nuevo** tuvo el golpe más fuerte (-80.7%), por encima de San Cristóbal (-73.1%) y La Aurora (-72.3%). Por **velocidad de recuperación** hacia el corte de entrenamiento (nivel del primer trimestre de 2021 como porcentaje de 2019), **Valle Nuevo** vuelve a ser la más golpeada: apenas **11.3%** de su nivel 2019, muy por debajo de San Cristóbal (26.6%) y sobre todo de La Aurora (35.8%, la que más recuperó nivel hacia esa fecha).

Conclusión: Valle Nuevo fue la más afectada por la pandemia, tanto en profundidad de la caída como en lentitud de la recuperación hasta el corte de entrenamiento.

6. Hallazgos generales: ¿qué descubrimientos serían más útiles para que el INGUAT tome decisiones?

1. **La vía terrestre concentra el grueso del turismo y de su tendencia de crecimiento**, por lo que las políticas de infraestructura fronteriza (capacidad de las fronteras, tiempos de trámite) tienen el mayor impacto potencial sobre el número total de viajeros -- mucho más que invertir proporcionalmente lo mismo en la vía aérea o marítima. Al bajar al detalle de fronteras específicas esto se confirma: Valle Nuevo (el paso terrestre de mayor volumen) es, en términos absolutos, la frontera que más viajeros/mes ha ganado desde 2009.
2. **No hay un solo modelo ganador ni por vía ni por frontera**, lo cual en sí mismo es un hallazgo operativo: Prophet ganó en Total, Terrestre, Valle Nuevo y San Cristóbal (series grandes o con quiebres de tendencia importantes); Holt-Winters ganó en Aérea y en La Aurora (la misma señal medida de dos formas -vía y frontera-, con estacionalidad limpia y regular); y el SARIMA clásico solo ganó en Marítima. Si INGUAT quiere pronósticos operativos por frontera o por vía, no debería usar un solo algoritmo para todas.
3. **Los SARIMA con doble diferenciación ($d=1$ y $D=1$) pueden ser numéricamente inestables en horizontes de pronóstico largos**, incluso cuando tienen el mejor AIC y pasan el diagnóstico de residuos dentro de muestra: en La Aurora y San Cristóbal, el modelo con menor AIC producía pronósticos que divergían a valores absurdos (10^{16} a 10^{41} viajeros) al proyectarlo 63 meses y revertir la transformación logarítmica. Esto es un hallazgo metodológico importante para cualquier equipo que automatice la selección de modelos por AIC/BIC sin revisar también la sensatez del pronóstico resultante.
4. **La recuperación pospandemia no fue pareja ni entre vías ni entre fronteras del mismo tipo**: entre los dos pasos terrestres hacia El Salvador, Valle Nuevo (el de mayor volumen) tuvo la caída más profunda y la recuperación más lenta hacia el corte de entrenamiento (2021 Q1), mientras que San Cristóbal, con menor volumen, se recuperó relativamente más rápido. Esto sugiere que las estrategias de reactivación fronteriza pospandemia no deberían asumir que "la frontera más grande se recupera más rápido" - el caso de Valle Nuevo muestra justamente lo contrario.
5. **Ningún modelo entrenado únicamente con datos hasta la pandemia logra anticipar adecuadamente ni la magnitud de la recuperación ni el cambio de metodología de clasificación de 2022-2023**. Esto es en sí un hallazgo importante para INGUAT: los modelos de pronóstico deben reentrenarse con frecuencia (no solo una vez), y cualquier cambio en la forma de recolectar o clasificar los datos (como el de 2022-2023) debe documentarse y comunicarse explícitamente, porque puede distorsionar por completo las comparaciones año a año si no se tiene en cuenta.